


SKRIPSI

**IDENTIFIKASI KEMATANGAN ROASTING KOPI DENGAN E-NOSE
BERBASIS *SUPPORT VECTOR MACHINE***

***IDENTIFYING THE ROASTING LEVEL OF COFFEE BEANS USING AN
E-NOSE BASED ON SUPPORT VECTOR MACHINE***



MUHAMMAD HASANI

20/456555/PA/19742

**PROGRAM STUDI S1 ELEKTRONIKA DAN INSTRUMENTASI
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA**

2024

HALAMAN PENGESAHAN

SKRIPSI

**IDENTIFIKASI KEMATANGAN ROASTING KOPI DENGAN ENOSE
BERBASIS SUPPORT VECTOR MACHINE**

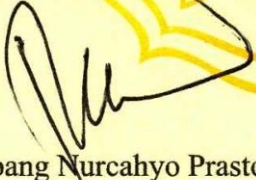
Telah dipersiapkan dan disusun oleh

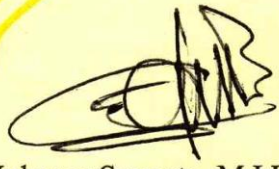
Muhammad Hasani

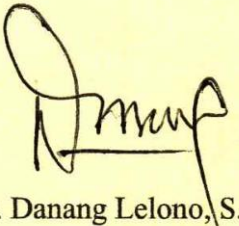
20/456555/PA/19742

Telah dipertahankan di depan Tim Penguji
pada tanggal 19 April 2024

Susunan Tim Penguji


Drs. Bambang Nurcahyo Prastowo, M.Sc.
Ketua Penguji


Dr. Yohanes Suyanto, M.I.Kom.
Anggota Penguji


Dr. Danang Lelono, S.Si., M.T
Pembimbing

Mengetahui,
a.n. Dekan FMIPA UGM
Wakil Dekan Bidang Pendidikan, Pengajaran
dan Kemahasiswaan



Prof. Drs. Roto, M.Eng., Ph.D.
NIP. 196711171993031020

SURAT PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan dibawah ini:

Nama : Muhammad Hasani

NIM : 20/456555/PA/19742

Tahun Daftar : 2020

Program Studi : Elektronika dan Instrumentasi

Fakultas : Fakultas Matematika dan Ilmu Pengetahuan Alam

Menyatakan bahwa dalam dokumen ilmiah skripsi ini tidak terdapat karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karta atau pendapat yang pernah ditulis atau diterbitkan oleh orang dan lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam Daftar Pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah skripsi ini dikemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau lembaga lain maka peneliti bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 15 April 2024



Muhammad Hasani

KATA PENGANTAR

Puji dan syukur kepada Tuhan Yang Maha Esa, atas berkat dan rahmat yang diberikan sehingga penulis dapat menyelesaikan skripsi ini yang berjudul “Identifikasi Kematangan Roasting Kopi Dengan E-Nose Berbasis *Support Vector Machine*”. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana S1 Program Studi Elektronika dan Instrumentasi, Departemen Ilmu Komputer dan Elektronika, Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Gadjah Mada.

Selama penulis berproses menempuh pendidikan S1 banyak bimbingan, bantuan, dan dukungan yang diberikan sehingga penulis dapat menyelesaikan studi dari awal hingga penelitian dan penulisan skripsi dapat selesai disusun. Pada kesempatan ini penulis menyampaikan ucapan terima kasih ditujukan kepada :

1. Allah Swt, atas limpahan berkat, rahmat, dan sehat yang diberikan sehingga penulis dapat menyelesaikan skripsi.
2. Kedua orang tua, serta seluruh keluarga tercinta yang hingga saat ini dan selalu memberikan doa dan semangat pada masa perkuliahan hingga menyelesaikan skripsi ini.
3. Bapak Dr. Danang Lelono, S.Si., M.T. yang telah meluangkan waktunya untuk membimbing serta memberikan ide dan saran serta motivasi bagi penulis sehingga dapat menyelesaikan skripsi ini dengan baik.
4. Dosen-dosen program studi Elektronika dan Instrumentasi yang telah memberikan ilmu dan membimbing selama masa perkuliahan.
5. Keluarga besar Elektronika dan Instrumentasi angkatan 2020 yang telah membersamai perjuangan selama proses pembelajaran selama masa kuliah.
6. Diandra, Gaung, dan Lulu yang telah meluangkan waktunya untuk memberikan saran, nasihat, dan membuka pemikiran penulis terhadap penelitian ini
7. Semua pihak yang telah berkontribusi yang tidak dapat disebutkan satu persatu.

Penulis menyadari bahwa tulisan skripsi ini masih terdapat kekurangan dan kesalahan karena keterbatasan kemampuan dan wawasan yang penulis miliki. Kritik dan saran yang bersifat membangun penulis harapkan demi perbaikan di masa mendatang. Penulis berharap tulisan skripsi ini dapat bermanfaat untuk penelitian selanjutnya.

Yogyakarta, 15 April 2024

A handwritten signature in black ink, appearing to read 'Muhammad Hasani', with a large, stylized flourish extending to the left.

Muhammad Hasani

DAFTAR ISI

HALAMAN PENGESAHAN	ii
SURAT PERNYATAAN BEBAS PLAGIASI	iii
KATA PENGANTAR	iv
DAFTAR ISI.....	vi
DAFTAR GAMBAR.....	ix
DAFTAR TABEL.....	x
INTISARI	xi
ABSTRACT.....	xii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah.....	3
1.4 Tujuan Penelitian	3
1.5 Manfaat Penelitian	3
1.6 Metodologi Penelitian	3
1.7 Sistematika Penulisan.....	4
BAB II TINJAUAN PUSTAKA	6
BAB III LANDASAN TEORI	13
3.1 Mesin Sangrai Kopi.....	13
3.2 Kopi Arabika	14
3.3 <i>Roast Level</i>	15
3.3.1 <i>Light Roast</i>	15
3.3.2 <i>Medium Roast</i>	15
3.3.3 <i>Dark Roast</i>	15
3.4 <i>Electronics Nose</i>	16
3.5 Sensor Gas.....	16
3.5.1 Sensor MQ135	16
3.5.2 Sensor MQ136	17
3.5.3 Sensor MQ137	17
3.5.4 Sensor MQ138	17
3.5.5 Sensor MQ2	17
3.5.6 Sensor MQ3	18

3.5.7 Sensor TGS822	18
3.5.8 Sensor TGS2620	18
3.6 <i>Machine Learning</i>	18
3.6.1 <i>Supervised Learning</i>	19
3.6.2 <i>Unsupervised Learning</i>	19
3.7 <i>Support Vector Machine (SVM)</i>	20
3.8 Pengujian	20
BAB IV METODE PENELITIAN	24
4.1 Analisis Sistem	24
4.2 Alat dan Bahan	24
4.3 Tahapan Penelitian	25
4.4 Rancangan Sistem	27
4.4.1 Rancangan Klasifikasi SVM	27
4.4.2 Rancangan Perangkat Keras	29
4.4.3 Proses Akuisisi dan Pengambilan Data	30
4.5 Rancangan Analisis	31
4.5.1 Confusion Matrix	31
4.5.2 Akurasi	31
4.5.3 Presisi	32
4.5.4 Recall	32
4.5.4 Spesitifitas	32
4.6 Pengujian Sistem	32
BAB V IMPLEMENTASI	34
5.1 Implementasi Perangkat Keras	34
5.1.1 Implementasi Elektronik dan aktuator	34
5.1.2 Implementasi Mekanik	38
5.2 Implementasi Akuisisi Data Sensor	40
5.2.1 Record Data sensor Gas	40
5.2.2 Visualisasi data sensor gas dalam bentuk grafik pada display Nextion ...	41
5.3 Analisis Dataset	42
5.3.1 Implementasi Pra Processing	42
5.3.2 Implementasi Ekstraksi Ciri	43
5.4 Implementasi Klasifikasi SVM	44
5.5 Implementasi Pengujian Hardware	46

BAB VI HASIL DAN PEMBAHASAN	47
6.1 Hasil Pembacaan Data.....	47
6.2 Hasil ciri pada setiap Kelas	48
6.3 Hasil Tahapan Klasifikasi	49
6.4 Hasil Pengujian Klasifikasi	49
6.5 Pengujian Model	51
BAB VII PENUTUP	54
7.1 Kesimpulan	54
7.2 Saran.....	54
DAFTAR PUSTAKA	56

DAFTAR GAMBAR

Gambar 3.1 Mesin Sangrai Jenis Air Roaster	13
Gambar 3.2 Mesin Sangrai Jenis Drum Roaster	14
Gambar 3.3 Contoh Aplikasi Supervised Learning (Rudolf, 2018).....	19
Gambar 3.4 Grafik Support Vector Machine (Rudolf, 2018)	20
Gambar 3.5 Matriks Kotak Confusion Matrix	21
Gambar 4.1 Tahap Penelitian	26
Gambar 4.2 Racangan Input Data	27
Gambar 4.3 Rancangan Klasifikasi SVM.....	27
Gambar 4.4 Rancangan Sistem Perangkat Keras	30
Gambar 5.1 Rangkaian Sensor Gas	35
Gambar 5.2 Rangkaian ADS1115 ADC to I2C	35
Gambar 5.3 Rangkaian USB to TTL.....	35
Gambar 5.4 Rangkaian Aktuator Vacuum Pump.....	36
Gambar 5.5 Rangkaian Level Shifter TXS0108EPWR	36
Gambar 5. 6 Hasil layout PCB	37
Gambar 5.7 Hasil Implementasi layout PCB	38
Gambar 5.8 Tampak perspektif	39
Gambar 5.9 Tampak belakang desain case alat.....	39
Gambar 5.10 Hasil implementasi desain case alat tampak perspektif	40
Gambar 5.12 Syntax Code akuisisi data sensor	40
Gambar 5.13 Program record data sensor gas	41
Gambar 5.14 Syntax Pemrograman visualisasi pada Nextion.	42
Gambar 5. 15 Syntax Pemrograman Normalisasi	43
Gambar 5.16 Library training dan testing	44
Gambar 5.17 Pembagian data testing dan data training	45
Gambar 5.18 Program training Model	45
Gambar 6.1 Respon sensor terhadap pembacaan aroma Light, Medium, dan Dark	47
Gambar 6.2 Visualisasi Ciri setiap kelasnya	48
Gambar 6.3 Confusion matrix pengujian secara realtime	52

DAFTAR TABEL

Tabel 2.1 Sensitivitas Sensor	8
Tabel 2.2 Korelasi Penelitian Terdahulu	10
Tabel 4. 1 Daftar Alat.....	24
Tabel 4.2 Daftar Bahan	25
Tabel 6. 1 . Hasil Pelatihan Model C 10 dengan Gamma Variatif.....	49
Tabel 6. 2 Hasil Pengujian Model C 10 dengan Gamma Variatif.....	49
Tabel 6.3 Hasil Pengujian Model secara realtime.....	52

INTISARI

IDENTIFIKASI KEMATANGAN ROASTING KOPI DENGAN E-NOSE BERBASIS *SUPPORT VECTOR MACHINE*

Oleh

Muhammad Hasani

20/456555/PA/19742

Kualitas kopi dipengaruhi oleh aroma dan warna. Kedua parameter ini banyak ditentukan pada saat proses roasting. Sedangkan hasilnya masih sangat bergantung pada kepakaran roaster. Namun hasil ini umumnya masih subyektif, sehingga standardisasi belum bisa dilakukan. Penelitian ini bertujuan untuk mengembangkan metode klasifikasi tingkat kematangan biji kopi selama proses roasting menggunakan electronic nose (e-nose). E-nose merupakan piranti yang dirancang untuk mendeteksi dan menganalisis perbedaan aroma kopi terkait dengan tingkat kematangan kopi secara objektif. Dalam penelitian ini, e-nose dilengkapi dengan larik sensor gas untuk menangkap aroma kopi selama proses roasting, yang kemudian dianalisis menggunakan metode support vector machine. Metode ini bertujuan untuk mengidentifikasi profil aroma yang berkaitan dengan tingkat kematangan kopi, dengan tujuan akhir menghasilkan klasifikasi tingkat kematangan kopi secara objektif dan otomatis.

E-nose dengan 8 sensor gas (MQ135, MQ136, MQ137, MQ138, MQ2, MQ3, TGS822, dan TGS2620) ditempatkan pada mesin roasting kopi untuk menentukan aroma pada tiga jenis roasting: light, medium, dan dark secara real-time. Dari 1 kg sampel kopi Arabika, sebanyak 18.000 data dikumpulkan (4.500 data per jenis roasting) dan dianalisis menggunakan metode support vector machine. Implementasi algoritma Support Vector Machine, pada e-nose telah menghasilkan model klasifikasi yang akurat dengan nilai akurasi dan presisi mencapai 99%. Performa model saat pengujian secara realtime didapatkan rerata akurasi 98,5%, recall 98,2%, spesifitas 98,7%, dan presisi 98%. Hasil pengujian yang dilakukan secara realtime menunjukkan bahwa model SVM mampu mengklasifikasikan aroma kematangan kopi dengan tingkat akurasi yang tinggi, menegaskan kemampuan teknologi e-nose dalam mendukung proses evaluasi kualitas kematangan kopi.

Kata Kunci: Tingkat Sangrai Kopi, *Electronic Nose*, *Support Vector Machine*

ABSTRACT

IDENTIFYING THE ROASTING LEVEL OF COFFEE BEANS USING AN E-NOSE BASED ON SUPPORT VECTOR MACHINE

By

Muhammad Hasani

20/456555/PA/199742

The quality of coffee is influenced by its aroma and color. These parameters are largely determined during the roasting process. However, the outcome is still heavily dependent on the expertise of the roaster. Yet, these outcomes are generally subjective, making standardization challenging. This study aims to develop a classification method for the maturity level of coffee beans during the roasting process using an electronic nose (e-nose). The e-nose is a device designed to detect and analyze differences in coffee aroma related to its maturity level objectively. In this study, the e-nose is equipped with an array of gas sensors to capture coffee aroma during the roasting process, which is then analyzed using support vector machine methods. The objective is to identify aroma profiles associated with the maturity level of coffee, ultimately aiming to achieve objective and automatic classification of coffee maturity levels.

The e-nose, equipped with 8 gas sensors (MQ135, MQ136, MQ137, MQ138, MQ2, MQ3, TGS822, and TGS2620), is placed on the coffee roasting machine to determine the aroma of three roasting types: light, medium, and dark, in real-time. From 1 kg of Arabica coffee samples, a total of 18,000 data points were collected (4,500 data points per roasting type) and analyzed using the Support Vector Machine method. The implementation of the Support Vector Machine algorithm on the e-nose has resulted in an accurate classification model with an accuracy and precision reaching 99%. The model's performance during real-time testing yielded an average accuracy of 98.5%, recall of 98.2%, specificity of 98.7%, and precision of 98%. Real-time testing results demonstrate that the SVM model is capable of classifying the aroma maturity of coffee with high accuracy, confirming the e-nose technology's ability to support the evaluation process of coffee maturity quality.

Keywords: Coffee Roast Level, Electronic Nose, Support Vector Machine

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kopi merupakan salah satu minuman yang paling populer yang dikonsumsi di seluruh dunia, karena memiliki cita rasa dan aroma yang khas. Negara Indonesia menjadi salah satu negara yang menghasilkan dua jenis kopi yaitu arabika dan robusta. Biji kopi yang dihasilkan merupakan salah satu komoditas unggulan bagi pendapatan nasional negara Indonesia. Pada tahun 2019 produksi kopi sebesar 752,51 ribu ton naik menjadi 762,38 ribu ton pada tahun 2020 atau naik sebesar 1,31 persen. Tahun 2021 produksi kopi naik menjadi 786,19 ribu ton atau meningkat sebesar 3,12 persen (Badan Pusat Statistik, 2021). Dalam meningkatkan pangsa pasar dan produktivitas jumlah ekspor kopi di Indonesia, diperlukan adanya kualifikasi dan klasifikasi pada biji kopi. Dalam proses kualifikasi dan klasifikasi tersebut, biji kopi akan dikualifikasi dari biji kopi yang masih dalam kategori biji kopi mentah (*greenbean*) hingga biji kopi yang telah disangrai, kemudian diklasifikasikan menjadi tiga profil *roast*, yaitu *light roast*, *medium roast*, dan *dark roast*.

Roast Level atau tingkat penyangraian biji kopi merupakan salah satu faktor terpenting yang menentukan cita rasa kopi di dalam cangkir. Pada dasarnya, cara yang paling umum untuk menggambarkan level sangrai kopi adalah dengan melihat hasil akhir warna biji kopi yang telah disangrai, mulai dari level sangrai terendah yaitu *light roast* (warna terang) sampai dengan *dark roast*/warna gelap (Agustina *et al.* 2019). Pada tahap *roast* biji kopi menghasilkan aroma akibat adanya penguapan senyawa volatil pada kopi yaitu alkohol, keton, dan aldehid. Pada umumnya aroma kopi dinilai oleh penguji kopi yang berpengalaman secara subjektif berdasarkan pengalaman dan kemampuan penguji tersebut. Kualitas kopi juga dapat dianalisis menggunakan dianalisis menggunakan *Gas Chromatography and Mass Spectroscopy (GC-MS)*. Metode ini memiliki kekurangan yaitu memerlukan finansial yang tinggi (Alexander *et al.*, 2017). Salah satu cara mengidentifikasi aroma tersebut perlu menggunakan piranti yang dapat mendeteksi

tiap gas yang berada pada area tersebut secara spesifik yang disebut dengan *electronic nose*.

Electronic Nose merupakan teknologi yang saat ini sedang dalam pengembangan. *Electronic Nose* atau yang sering disebut dengan *e-nose* sendiri merupakan piranti yang dirancang dengan menirukan cara kerja indera penciuman manusia. *Electronic nose* dirancang dengan menggunakan sistem olfaktori elektronik yang cara kerjanya dengan cara menangkap bau atau aroma yang ditangkap oleh *array* odor sensor atau larik sensor gas (Lelono et al., 2013). Digunakan sensor berbasis *array* karena dalam aroma biji kopi terdapat berbagai kandungan gas sehingga perlu dilakukan identifikasi dari gas yang terkandung dalam aroma untuk mendapatkan hasil keluaran gas yang dapat digunakan untuk klasifikasi dalam menentukan tingkat kematangan biji kopi selama proses *roasting* kopi.

Secara umum, penggunaan *e-nose* telah banyak digunakan dalam klasifikasi varietas kopi dan telah dikembangkan dengan baik, namun penerapannya dalam klasifikasi tingkat kematangan kopi masih terbatas. Tingkat kematangan biji kopi mempengaruhi profil aroma yang dihasilkan, dan tingkat kematangan kopi memiliki nilai penting dalam industri kopi. Saat ini dalam penilaian tingkat kematangan kopi masihi dilakukan secara subjektif oleh para ahli atau penikmat kopi berdasarkan pengamatan visual dengan memperhatikan perubahan warna saat proses *roasting* kopi untuk mengindikasikan tingkat kematangannya. Pada penggunaan *e-nose* dalam klasifikasi tingkat kematangan kopi untuk mendeteksi dan menganalisis perbedaan aroma terkait dengan tingkat kematangan kopi, sehingga dapat menghasilkan tingkat kematangan biji kopi secara objektif.

1.2 Rumusan Masalah

Berdasarkan permasalahan pada latar belakang di atas dapat dirumuskan proses *roasting* kopi bersifat manual dan bergantung sepenuhnya pada kepakaran roaster sehingga penentuan kualitas jenis light, medium dan dark.

1.3 Batasan Masalah

Batasan masalah yang digunakan dalam penelitian ini adalah:

1. Proses klasifikasi biji kopi hanya terbatas pada jenis kopi Arabika Ijen
2. Jenis klasifikasi kematangan biji kopi terbatas pada *light roast*, *medium roast*, dan *dark roast*.
3. Takaran biji kopi terbatas 10 Kg
4. Sensor yang digunakan (MOS dan TGS *series* sejumlah 8)
5. *Supervised* model yang digunakan adalah *Support Vector Machine*

1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah untuk merancang sistem pada mesin roasting kopi yang dapat mengidentifikasi aroma tingkat kematangan roasting kopi menggunakan e-nose berbasis algoritma Support Vector Machine.

1.5 Manfaat Penelitian

Dengan menggunakan sistem identifikasi kematangan *roasting* biji kopi secara *real-time* menggunakan *e-nose* dan algoritma *supervised learning*. Dapat menghasilkan kualitas kopi yang lebih konsisten dan optimal. Identifikasi yang objektif dan akurat dapat meminimalkan kesalahan dalam identifikasi kematangan *roasting*. Sehingga menghasilkan kopi dengan cita rasa yang lebih konsisten dan berkualitas tinggi.

1.6 Metodologi Penelitian

Tahapan yang dilalui dalam penelitian ini adalah sebagai berikut:

1. Identifikasi Masalah
Melakukan identifikasi masalah-masalah yang ada untuk mencari topik yang akan diselesaikan pada penelitian ini. Pemilihan topik akan dianalisa kemudian dicari solusi permasalahannya.
2. Analisis Masalah
Menganalisis permasalahan untuk ditemukan kemungkinan solusinya. Kemungkinan solusi yang ada dari permasalahan tersebut dapat digunakan untuk merumuskan tujuan dari sistem yang akan dibuat.
3. Studi Literatur

Memahami permasalahan secara lebih mendalam dengan pengkajian dan pembelajaran lebih lanjut dari literatur terkait topik permasalahan dan mengembangkan solusi yang dapat digunakan dan teruji pada penelitian terdahulu.

4. Perancangan Sistem

Rancangan sistem untuk penelitian ini dibagi menjadi dua bagian, yaitu:

- a. Perancangan alat, yaitu proses pembuatan alat *e-nose* sebagai media untuk proses pengambilan data.
- b. Perancangan perangkat lunak, yaitu pembuatan program sistem klasifikasi data *e-nose*.

5. Pengaplikasian dan Percobaan Sistem

Pada tahap ini dilakukan implementasi rancangan sistem yang sebelumnya dibuat.

6. Pengujian Sistem

Menguji sistem dengan kumpulan data uji dan melakukan evaluasi terhadap hasil/*output* yang dikeluarkan sistem klasifikasi.

7. Penyusunan Laporan

Dilakukan penulisan laporan akhir tentang hasil dan proses penelitian.

1.7 Sistematika Penulisan

Sistematika penulisan dalam penyusunan usulan penelitian S1 ini adalah sebagai berikut:

BAB I: PENDAHULUAN

Bab ini berisi tentang latar belakang masalah yang akan dikaji, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, serta sistematika penulisan laporan penelitian.

BAB II: TINJAUAN PUSTAKA

Bab ini berisi penelitian-penelitian terdahulu terkait dengan topik klasifikasi tingkat kematangan biji kopi arabika dengan menggunakan

sistem pembelajaran mesin. Hasil penelitian akan dijadikan sebagai referensi dan bahan perbandingan terhadap penelitian ini.

BAB III: LANDASAN TEORI

Bab ini berisi tentang penjabaran teoritis mengenai istilah-istilah yang akan mendukung proses penelitian ini. Teori-teori yang dimaksud termasuk namun tidak terbatas pada pengertian *e-nose*, parameter pendukung, klasifikasi, pembelajaran mesin, *Support Vector Machine (SVM)*, dan Pengujian

BAB IV: METODE PENELITIAN

Bab ini berisi tentang penjelasan mengenai rancangan sistem secara keseluruhan meliputi perangkat keras, perangkat lunak, serta proses pemodelan sistem dan rangkaian pengujian sistem

BAB V: JADWAL PENELITIAN

Bab ini berisi tabel yang menunjukkan rencana waktu penelitian. Rencana waktu penelitian dimulai dari penyusunan proposal sampai pembuatan laporan akhir. Jadwal penelitian dibutuhkan untuk mengetahui progres dari penelitian yang telah dilakukan.

BAB II

TINJAUAN PUSTAKA

Kematangan biji kopi arabika merupakan faktor yang mempengaruhi kualitas dari biji kopi setelah diseduh. Tingkat kematangan yang tepat dapat menghasilkan rasa dan aroma yang diinginkan. Tingkat kematangan yang kurang atau berlebihan dapat menghasilkan rasa dan aroma yang tidak diinginkan. Pada awalnya dalam proses tingkat kematangan dilakukan secara visual dan pemahaman subjektif manusia, sehingga hasilnya belum terstandardisasi dan memungkinkan terjadi *human error*. Dalam penulisan proposal ini, peneliti berusaha mengumpulkan informasi dari beberapa sumber penelitian serta laporan yang telah dilaksanakan sebelumnya sebagai perbandingan untuk kelebihan dan kekurangan yang ada.

Penelitian *Smart Coffee Roaster Design with Connected Devices* oleh Xu, (Shaull et al., 2018) membuat desain *roasting* kopi pintar yang dapat memonitoring suhu, suara retakan pada biji kopi, karbon monoksida dan bisa dikontrol melalui jarak jauh. Pada desain perangkat keras menggunakan resistansi *thermal* yang dipasang pada drum untuk mendeteksi suhu pada drum. Untuk mendeteksi suara retakan yang terjadi pada proses *roasting* kopi menggunakan mikrofon MAX4466. Pada proses deteksi gas yang dihasilkan dari proses *roasting* menggunakan sensor gas MQ-7 untuk mendeteksi kadar karbon monoksida. Perangkat keras yang dirancang terhubung dengan *smartphone* melalui *bluetooth* yang dapat menampilkan dan mengendalikan *roaster* secara *real time*. Metode yang digunakan dalam proses *roasting* menggunakan sistem monitoring grafik dari sensor yang terpasang kemudian ditentukan *threshold* untuk tingkat kematangan yang diinginkan. Jika tingkat kematangan biji kopi yang diinginkan tercapai, sistem akan berhenti secara otomatis.

Kopi yang banyak dihasilkan di Indonesia yaitu kopi Arabika dan kopi Robusta. Tiap daerah di Indonesia memiliki kualitas serta aroma dan rasa yang khas, salah satunya jenis kopi arabika Gayo dari Provinsi Aceh. Berbagai faktor dapat mempengaruhi hasil akhir kopi salah satunya pada proses pengolahan pasca

panen. Perbedaan metode pengolahan pada kopi berpengaruh pada aroma kopi yang dihasilkan. Diimplementasikan seleksi fitur pada proses klasifikasi menggunakan metode *Support Vector Machine* (SVM) berdasarkan jumlah galat *Sum of Absolute Errors* (SAE) untuk mendapatkan kombinasi fitur terbaik dapat diaplikasikan sehingga mendapatkan kinerja yang lebih optimal. Hasilnya adalah didapat susunan kombinasi fitur terbaik utama dengan 5 kombinasi yakni *mean*, *skewness*, *kurtosis*, daya spektrum frekuensi ke-1, dan daya spektrum frekuensi ke-4 dengan kinerja yang lebih baik dari pengaplikasian seluruh fitur dengan nilai akurasi 93,33%, presisi 93,33%, dan sensitivitas 93,33%. Kombinasi dari hasil seleksi fitur terbaik tersebut dapat mengoptimalkan kinerja sistem. (Sumanto et al., 2022)

Terinspirasi oleh prinsip penciuman biologis, *electronic nose* dikembangkan oleh kombinasi teknologi penginderaan modern, teknologi elektronik dan teknologi pengenalan pola yang telah menarik perhatian di banyak bidang. Namun, sensor gas tradisional berdasarkan semikonduktor oksida membutuhkan suhu kerja yang lebih tinggi, sehingga *electronic nose* biasanya berukuran besar dan konsumsi daya tinggi dan membatasi pengembangan *electronic nose*. Sistem yang dibuat dirancang secara independen dengan susunan sensor enam saluran berdasarkan bahan penginderaan gas CQD yang dapat digunakan untuk mengidentifikasi berbagai bau atau gas. *Electronic nose* akan mengenali atmosfer kompleks dengan perbedaan besar. Bahan penginderaan gas CQD konduktif untuk miniaturisasi dan konsumsi daya yang rendah dari *electronic nose*. Untuk membedakan atmosfer dengan celah yang lebih kecil, diperlukan lebih banyak susunan sensor dan uji *throughput* tinggi. Dalam penelitian, tes sensor gas dilakukan pada minuman keras, bir, kopi dan teh (L. Li et al, 2019).

Penelitian *Freshness Evaluation of Beef using MOS Based E-Nose* oleh (Binson et al, 2023) melakukan klasifikasi kesegaran daging sapi menggunakan *Electronic Nose* yang tersusun dari delapan sensor (4 sensor TGS *series* dan 4 MQ *series*) menggunakan mikrokontroler arduino mega. Data sensor dikumpulkan dari arduino sebagai keluaran analog yang kemudian disimpan dalam log excel. Data yang dikumpulkan dianalisis menggunakan algoritma *machine learning*

menggunakan *software* Matlab. Metode yang digunakan yaitu SVM, Decisison TREE, Linear Discriminant Algorithm, Logistic Regression, dan Gussian Naïve Bayes. Parameter yang dihasilkan yaitu akurasi, sensitivitas, dan spesifikasi. Dari keempat metode tersebut, SVM (*Support Vector Machine*) mencapai akurasi tertinggi dengan nilai 91.5%, sedangkan *Gaussian Naive Bayes* menunjukkan kinerja yang lebih rendah dengan akurasi hanya 60.8%. KNN, *Decision Tree*, *Linear Discriminant Algorithm*, dan *Logistic Regression* memiliki akurasi yang serupa, berkisar antara 85.9% hingga 89.9%. Oleh karena itu, SVM merupakan metode yang lebih baik dalam penelitian ini, sementara Gaussian Naive Bayes tidak efektif untuk klasifikasi kesegaran daging sapi.

Penelitian *Classification of Coffee Variety using Electronic Nose* oleh (Delmo et al., 2022) *e-nose* akan digunakan untuk membedakan varietas kopi berdasarkan empat jenis kopi yang di produksi secara komersial yaitu arabica, robusta, excelsa, dan liberica. Menggunakan sensor gas jenis MOS yaitu MQ2, MQ7, MQ135, dan MQ137 untuk menganalisis korelasi sensor. Sensor tersebut memiliki sensitivitas terhadap gas yang dapat dilihat pada tabel 2.1

Tabel 2.1 Sensitivitas Sensor

Sensor	Sensitivitas
MQ2	LPG, Butana, Propana, Metana, Alkohol, Asap, Hidrogen
MQ7	Karbon Monoksida
MQ135	Karbondioksida
MQ137	Amonia (NH ₃)

Kemudian dilakukan pengujian *e-nose* pada sampel biji kopi, diperoleh 198 data dari sensor dan 12 data dari masing masing empat pembacaan sensor dari masing masing sampel varietas biji kopi. Setiap pembacaan sensor kemudian dibandingkan dengan sensor gas lainnya untuk dianalisis lebih lanjut dari korelasi sensor. Dari pendeteksian keempat varietas kopi, terkumpul sebanyak 198 data yang telah dilakukan *training* dan metode klasifikasi. Gas yang terdeteksi pada

kopi arabika, robusta, excelsa, dan liberica telah diklasifikasikan dengan menerapkan metode *Gaussian Naïve Bayes* dan mendapatkan tingkat akurasi hampir 100%, membandingkan akurasi yang diperoleh dalam penelitian ini dengan pemanfaatan SVM dengan tingkat akurasi 71% dan Perceptron dengan tingkat akurasi 67%.

Penelitian *Classification Of Arabica And Robusta Coffee Using Electronic Nose* oleh (Magfira et al., 2018) melakukan klasifikasi kopi arabika dan robusta menggunakan satu sensor gas yaitu MQ135. Sensor MQ135 memiliki kepekaan terhadap gas; CO₂, O₂, NH₃, alkohol, benzena dan asap. Penelitian ini menggunakan dua metode untuk membandingkan akurasi dari hasil analisis yang diperoleh. Metode pertama menggunakan *Support Vector Machine* (SVM), SVM dapat menentukan *hyper-location* terbaik yang dapat memisahkan dua kelas input. SVM dapat diterapkan pada data linear maupun non-linear. Metode kedua menggunakan *Perceptron*, *perceptron* dibuktikan dengan konvergen menjadi bobot yang benar menghasilkan nilai output yang benar untuk setiap pola input training data. Dari pendeteksian kopi arabika didapat data sebanyak 288 data pada setiap pendeteksian yang dilakukan, pendeteksian dilakukan sebanyak tiga kali untuk setiap jenis kopi. Terdapat tiga jenis kopi yang digunakan yaitu arabika gayo, arabika malabar, dan arabika lintong. Dari hasil deteksi gas pada kopi arabika dan robusta akan dilakukan klasifikasi dengan menerapkan dua metode klasifikasi yaitu *Support Vector Machine* (SVM) dan metode *Perceptron* untuk mendapatkan nilai akurasi dari hasil pengujian. Dari hasil klasifikasi yang dilakukan, nilai akurasi yang lebih tinggi dihasilkan dari metode *Support Vector Machine* (SVM). Pada pengelompokan ini, *Support Vector Machine* (SVM) mampu mengelompokkan jenis kopi arabika dan robusta dengan nilai akurasi sebesar 71% dan nilai error sebesar 0.53452. Dan untuk hasil dari metode *Perceptron* mendapatkan akurasi sebesar 57% dengan nilai *error* sebesar 0.65465.

(Rusman, et al., 2019) menggunakan *e-nose* untuk mengklasifikasi 3 kelas mutu biji kakao jawa unggulan, yaitu kakao *dark bean* < 20 %, kakao *dark 9 bean* > 60 %, dan kakao curah, dimana ketiga kakao tersebut tidak mudah dibedakan dari segi kualitas yang tinggi dan rendah. *E-nose* yang digunakan terdiri dari

delapan sensor *metal oxide semiconductor* (MOS) dengan sensor kelembaban dan sensor suhu. Tiga kelas sampel kakao diuji pada *e-nose* dengan masing-masing seratus kali uji sehingga mendapatkan data total sebanyak tiga ratus data. Sebelum melakukan analisis klasifikasi, dilakukan pra pemrosesan data dengan data yang didapat dinormalisasikan. Selanjutnya dilakukan ekstraksi ciri dengan menggunakan nilai maksimum respon sensor. Terdapat dua metode klasifikasi yang digunakan yaitu ANN dan SVM. Data terlebih dahulu dibagi menjadi dua subset yaitu *training* set dan *testing* set dengan menggunakan algoritma *Kennard Stone* dengan *ratio* 80:20. Selanjutnya dikembangkan model klasifikasi dengan 10-fold *cross validation*, SVM menggunakan kernel *Radial Basis Function* (RBF) dengan melakukan *hyper* parameter tuning menggunakan metode *grid search*, dengan nilai *cost* (C) diatur sebesar 0,01, 0,1, 1, 10, 100, dan 1000, sedangkan nilai *gamma* diatur sebesar 0,001, 0,01, 0,1, 1, 10, 100, dan 1000, SVM berhasil mengklasifikasi dengan *training* set 99% dan *testing* set 90%.

Rangkuman perbandingan dan korelasi penelitian terdahulu yang digunakan sebagai acuan dalam penelitian ini adalah sebagai berikut.

Tabel 2.2 Korelasi Penelitian Terdahulu

No	Author (Tahun)	Judul	Keterangan
1	(Shaull et al., 2018)	<i>Smart Coffee Roaster Design with Connected Devices</i>	Membuat <i>roasting</i> kopi pintar yang dapat memonitoring suhu, <i>crack</i> , dan karbon monoksida dan bisa dikontrol melalui jarak jauh. menggunakan mikrofon MAX4466 dan sensor gas MQ-7. Menggunakan metode monitoring grafik sensor dengan <i>threshold</i> tingkat kematangan.

Tabel 2.3 Korelasi Penelitian Terdahulu (lanjutan)

2	(Sumanto et al., 2022)	<i>Seleksi Fitur Terhadap Performa Kinerja Sistem ENose untuk Klasifikasi Aroma Kopi Gayo</i>	Sistem <i>E-Nose</i> digunakan untuk mengklasifikasi aroma yang berbeda dari jenis kopi Gayo natural dan Gayo wine menggunakan metode SVM berdasar jumlah galat SAE dengan hasil nilai akurasi 93,33%, presisi 93,33%, dan sensitivitas 93,33%.
3	(L. Li et al, 2019).	<i>Construction and Simple Application of a Primary Electronic Nose System</i>	<i>Electronic nose</i> yang dibuat berdasarkan penginderaan gas CDQ yang memiliki konsumsi daya rendah.
4	(Binson et al, 2023)	<i>Freshness Evaluation of Beef using MOS Based E-Nose</i>	Electronic Nose yang terdiri dari delapan sensor untuk mengklasifikasikan kesegaran daging sapi. Data sensor dikumpulkan melalui mikrokontroler Arduino Mega dan dianalisis menggunakan algoritma machine learning menggunakan MATLAB. Dari lima metode yang digunakan, SVM mencapai akurasi tertinggi sebesar 91.5%, sementara <i>Gaussian Naive Bayes</i> memiliki kinerja yang lebih rendah dengan akurasi hanya 60.8%. <i>KNN</i> , <i>Decision Tree</i> , <i>Linear Discriminant Algorithm</i> , dan <i>Logistic Regression</i> memiliki akurasi serupa, berkisar antara 85.9% hingga 89.9%.
5	(Delmo et al., 2022)	<i>Classification of Coffee Variety using Electronic Nose</i>	<i>E-nose</i> digunakan untuk membedakan varietas empat jenis kopi yaitu arabica, robusta, excelsa, dan liberica. Dari pendeteksian keempat varietas kopi, terkumpul sebanyak 198 data yang telah dilakukan <i>training</i> dan metode klasifikasi. Gas yang terdeteksi pada kopi arabika, robusta, excelsa, dan liberica telah diklasifikasikan dengan menerapkan metode <i>Gaussian Naïve Bayes</i> dan mendapatkan tingkat akurasi hampir 100%, membandingkan akurasi yang diperoleh dalam penelitian ini dengan pemanfaatan SVM dengan tingkat akurasi 71% dan <i>Perceptron</i> dengan tingkat akurasi 67%.

Tabel 2.4 Korelasi Penelitian Terdahulu (lanjutan)

6	(Magfira et al., 2018)	<i>Classification Of Arabica And Robusta Coffee Using Electronic Nose</i>	<i>E-Nose</i> digunakan klasifikasi kopi arabika dan robusta menggunakan satu sensor gas yaitu MQ135. Dari pendeteksian kopi arabika didapat data sebanyak 288 data pada setiap pendeteksian yang dilakukan, pendeteksian dilakukan sebanyak tiga kali untuk setiap jenis kopi. Terdapat tiga jenis kopi yang digunakan yaitu arabika gayo, arabika malabar, dan arabika lintong. Menerapkan dua metode klasifikasi yaitu <i>Support Vector Machine</i> (SVM) dan metode <i>Perceptron</i> untuk mendapatkan nilai akurasi dari hasil pengujian. <i>Support Vector Machine</i> (SVM) mampu mengelompokkan jenis kopi arabika dan robusta dengan nilai akurasi sebesar 71% dan nilai <i>error</i> sebesar 0.53452. Dan untuk hasil dari metode <i>Perceptron</i> mendapatkan akurasi sebesar 57% dengan nilai <i>error</i> sebesar 0.65465.
7	(Rusman, et al., 2019)	<i>Electronic nose coupled with linear and nonlinear supervised learning methods for rapid discriminating quality grades of superior java cocoa beans</i>	<i>E-nose</i> untuk mengklasifikasi 3 kelas mutu biji kakao jawa unggulan, yaitu kakao <i>dark bean</i> < 20 %, kakao <i>dark 9 bean</i> > 60 %, dan kakao curah, dimana ketiga kakao tersebut tidak mudah dibedakan dari segi kualitas yang tinggi dan rendah. Tiga kelas sampel kakao diuji pada <i>e-nose</i> dengan masing-masing seratus kali uji sehingga mendapatkan data total sebanyak tiga ratus data. Menggunakan metode SVM berhasil mengklasifikasi dengan <i>training</i> set 99% dan <i>testing</i> set 90%.

BAB III

LANDASAN TEORI

3.1 Mesin Sangrai Kopi

Mesin sangrai kopi pada dasarnya terdapat dua jenis yaitu *drum* atau disebut *semi hot air* dan *hot air*. Mesin sangrai kopi jenis drum atau *semi hot air* atau *indirectly heated drum* memiliki keunikan masing-masing sesuai dengan produsennya baik dari estetika, harga dan lain lain, namun semua memiliki fungsi yang sama yaitu memanaskan biji kopi dari suhu ruangan sampai 230C. Salah satu bagian terpenting dari mesin sangrai kopi yaitu adalah *drum* sangrai dan juga *airflow*. Mesin sangrai *semi hot air* memiliki *drum* yang berputar secara horizontal untuk mengaduk biji kopi. Biasanya mesin sangrai *drum* ini mendapatkan sumber panasnya dari bahan bakar gas cair (LPG), dan paling banyak sumber panas berada di bawah drum mesin sangrai. Ada beberapa jenis mesin sangrai yang umum digunakan saat ini yaitu *Air Roaster* dan *Drum Roaster*.

1. Air Roaster

Air Roaster Atau Hot Air Roaster, adalah mesin yang menggunakan aliran cepat dari udara panas ke biji kopi yang disangrai. Ada berbagai jenis, atau konfigurasi dari mesin sangrai *hot air* ini, tapi semua menggunakan udara panas untuk konveksi terhadap biji kopi dan untuk membantu menjaga kopi terus bergerak tidak menyentuh *chamber* sangrai. Kebanyakan digunakan untuk skala komersil atau industri.



Gambar 3.1 Mesin Sangrai Jenis Air Roaster

2. *Drum Roaster*

Drum Roaster atau *Semi Hot Air* menggunakan teknologi sederhana yang belum benar-benar berubah banyak selama bertahun-tahun. Dalam arti dasar, *drum roaster* adalah hanya sebuah silinder yang berputar pada sumbu horisontal. Sirip yang berada pada *drum* mencampur atau mengaduk kopi dan mengalirkan udara panas melalui *drum*. Ada dua jenis *Drum roaster*: *drum* yang padat dan *drum* yang berlubang.



Gambar 3.2 Mesin Sangrai Jenis *Drum Roaster*

3.2 Kopi Arabika

Kopi arabika merupakan salah satu jenis kopi yang banyak di budidayakan di Provinsi Sulawesi Selatan. Kopi arabika termasuk dalam tanaman buah yang memiliki waktu panen dan tingkat kematangan tertentu. Kopi arabika biasanya berwarna hijau saat muda, agak kekuningan sampai kemerahan saat setengah tua dan merah terang sampai merah gelap saat sudah tua (Abdullah et al., 2010). Tingkat kematangan buah kopi arabika mempengaruhi kandungan senyawa kimia dalam biji kopi, terutama kafein. Kadar kafein dalam biji kopi berbeda tergantung pada tingkat kematangan saat buah kopi dipanen. Tujuan dari penelitian ini yaitu untuk mengetahui kadar kafein kopi arabika pada tingkat kematangan muda, sedang dan tua dan mengetahui kadar kafein tertinggi dan terendah kopi arabika pada tingkat kematangan muda, sedang dan tua.

3.3 *Roast Level*

Roast Level atau tingkat penyangraian biji kopi merupakan salah satu faktor terpenting yang menentukan cita rasa kopi di dalam cangkir. Pada dasarnya, cara yang paling umum untuk menggambarkan *level* sangrai kopi adalah dengan melihat hasil akhir warna biji kopi yang telah disangrai, mulai dari *level* sangrai terendah yaitu *light roast* (warna terang) sampai dengan *dark roast*/warna gelap (Agustina et al. 2019).

3.3.1 *Light Roast*

Pada tingkat *light roast*, biji yang disangrai akan memiliki tingkat kematangan yang paling rendah dibandingkan dengan tingkat *roasting* lainnya. Tingkat panggang jenis ini tidak terlalu harum. Biji kopi akan berwarna coklat muda, dan tidak ada lapisan minyak pada permukaan biji. Pada tingkat *light roast*, keasaman lebih dominan. Olahan *light roast* memiliki rasa biji yang masih segar dan masih berasa buah (*fruity/vegetable*), dan biasanya *light roast* juga memiliki *short after taste* (kekentalan rasa). Bagi yang menyukai kualitas rasa kopi seperti rasa original, tingkat *light roast* ini bisa direkomendasikan. Dalam jenis *roast level* ini ada beberapa nama *roast* yang populer disebut *Light City*, *Half City*, *Cinnamon Roast* dan *New England Roast*. (Bahrumi, P.2022).

3.3.2 *Medium Roast*

Aroma biji kopi yang telah disangrai (*roast beans*) sangat jelas pada tingkat *medium roast*, warna biji kopi lebih gelap dibandingkan pada tingkat *roasting* sebelumnya, dan kandungan gula alami pada biji kopi sudah mulai berkarbonasi dan sedikit karamel. pada level ini, membuat rasa kopi terasa sedikit manis. Pada tingkat *roasting* ini, rasa, aroma, dan keasaman semuanya seimbang (*balance/kompleks*), atau lebih tepatnya kaya rasa. Tingkat pemanggangan ini disebut dengan sejumlah nama pemanggangan, antara lain *Regular Roast*, *American Roast*, *City Roast*, dan *Breakfast Roast*. (Bahrumi, P.2022)

3.3.3 *Dark Roast*

Warna biji kopi akan lebih gelap pada tingkat *dark roast* dibandingkan pada tingkat sebelumnya yaitu coklat agak kehitaman. Jika biji kopi disangrai melebihi titik ini, biji yang dihasilkan akan terlalu matang, yang jelas berdampak buruk bagi

kesehatan manusia. Biji kopi akan melepaskan lapisan minyak yang tebal di permukaannya pada tingkat pemanggangan ini. Pada tingkat *dark roast*, rasa kopi lebih menonjol; itu pahit (pahit) dan sedikit berasap (berasap); Bisa dibilang kualitas rasa sudah menutupi keunikan rasa kopinya. Jika sudah terjadi retakan kedua, proses pemanggangan pada *level* ini dapat segera dihentikan. Bagi yang lebih menyukai kopi dengan *body* yang kental, *level dark roast* sangat ideal. Ada beberapa nama hidangan yang terkenal dengan tingkat *dim meal* seperti ini, yaitu *French Meal*, *Italian Meal*, *Coffee Cook*, *Mainland Broil*, *New Orleans Meal*, dan *Spanish Meal*. (Bahrumi, P.2022)

3.4 *Electronics Nose*

Electronic Nose (E-Nose) merupakan sebuah alat yang meniru cara kerja hidung manusia. *Electronic Nose* disusun oleh beberapa sensor gas yang memiliki fungsi mendeteksi bau/aroma yang meniru struktur larik saraf penciuman dalam olfaktori manusia. Keluaran *E-Nose* dapat berupa pola-pola yang mewakili masing masing bau/aroma sehingga dapat diterapkan untuk identifikasi, perbandingan, kuantifikasi dan klasifikasi berdasarkan aroma (Telaumbanua, et al., 2021; Baskara, et al., 2016). Berbagai reseptor yang dapat mengidentifikasi aroma bau terdapat di dalamnya. Reseptor ini fungsinya digantikan oleh sensor pada teknologi *E-Nose*. Setiap reseptor memberikan respon yang berbeda dari uap aroma yang sama (Kusumadewi, 2004). Perangkat ini telah mengalami banyak pengembangan serta digunakan untuk memenuhi kebutuhan industri dan lain-lain (Sitohang, 2012).

3.5 **Sensor Gas**

Sensor elektrokimia merupakan peralatan pendeteksi polutan gas yang bekerja berdasarkan reaksi antara komponen sensor dengan analit yang dapat berupa gas atau ion kemudian menghasilkan sinyal elektrik yang setara dengan konsentrasi analit

3.5.1 **Sensor MQ135**

Sensor MQ-135 digunakan untuk mendeteksi gas gas amonia (NH₃), natrium(di)oksida (NO_x), alkohol/ethanol (C₂H₅OH), benzena (C₆H₆), karbondioksida (CO₂), gas belerang/sulfur-hidroksida(H₂S) dan asap/gas-gas lainnya di udara. Material sensitif yang digunakan pada sensor ini adalah SnO₂ (*Tin*

Oxide). Konduktivitas bahan SnO₂ yang lebih rendah di udara bersih, konduktivitas sensor ini lebih tinggi seiring dengan kenaikan gas konsentrasi. Jangkauan deteksi sensor MQ 135 adalah 10- 10.000 ppm dengan tingkat tegangan sekitar 5.0V \pm 0.1V AC atau DC. (Abbas et al., 2020)

3.5.2 Sensor MQ136

Sensor MQ-136 adalah suatu komponen semikonduktor yang berfungsi sebagai pengindera bau gas tin oksida (SnO₂). Sensor gas MQ136 memiliki sensitivitas tinggi terhadap SO₂, juga bisa digunakan untuk mendeteksi uap lain yang mengandung Sulfur. Ini memiliki sensitivitas rendah terhadap gas yang mudah terbakar normal, dengan biaya rendah dan sesuai untuk aplikasi yang berbeda. (Datasheet MQ136)

3.5.3 Sensor MQ137

Sensor MQ 137 merupakan golongan sensor sensitif yang terbuat dari material gas tin oksida (SnO₂) dengan konduktivitas rendah jika berada di udara bersih dan konduktivitasnya meningkat bersamaan dengan kenaikan konsentrasi gas yang dideteksi. Untuk mengkonversi perubahan konduktivitas sesuai dengan konsentrasi gas yang digunakan pada rangkaian elektrosirkuit sederhana.

3.5.4 Sensor MQ138

Sensor MQ-138 merupakan sensor semikonduktor yang bekerja Bersama dengan penghirup udara dan mikrokontroler untuk mengambil data dari napas pasien. Sensor MQ-138 dilapisi oleh bahan semikonduktor yang mempunyai nilai konduktivitas rendah pada udara normal. Apabila udara sekitar sensor terdapat aroma lain, maka konduktivitas sensor meningkat tergantung dari jenis aroma dan konsentrasi yang terkandung.

3.5.5 Sensor MQ2

Sensor MQ2 merupakan sensor yang mendeteksi gas yang mudah terbakar seperti LPG, CH₄, butana, metana, dan asap karbon. Semikonduktor SnO₃ merupakan bahan dari sensor MQ2 yang memiliki konduktivitas rendah pada udara bersih sehingga saat sensor mendeteksi adanya gas maka konduktivitas sensor akan semakin tinggi (Radimas Putra et al., 2019).

3.5.6 Sensor MQ3

Sensor MQ3 adalah komponen elektronika yang dapat mendeteksi kadar alkohol pada udara. Sensor MQ3 memiliki kepekaan yang tinggi terhadap alkohol dan kepekaan yang rendah terhadap bensin. Selain dapat mendeteksi alkohol, sensor ini juga dapat mendeteksi etanol dan asap rokok. Sensor MQ3 memiliki waktu respon cepat, stabil, dan tahan lama.

3.5.7 Sensor TGS822

TGS 822 memiliki sensitivitas yang tinggi terhadap uap pelarut organik serta mudah menguap. TGS 822 juga memiliki kepekaan terhadap berbagai gas yang mudah terbakar seperti karbon monoksida, sehingga sensor umum digunakan. Juga tersedia dengan keramik dasar yang sangat tahan terhadap lingkungan yang parah setinggi 200 °C. Elemen penginderaan sensor gas Figaro adalah dioksida timah (SnO₂) semikonduktor yang memiliki konduktivitas rendah di udara bersih. Dengan keberadaan gas terdeteksi, yang meningkatkan konduktivitas sensor tergantung pada konsentrasi gas di udara. Sebuah rangkaian listrik sederhana dapat mengkonversi perubahan konduktivitas untuk sinyal output yang sesuai dengan konsentrasi gas.

3.5.8 Sensor TGS2620


Sensor TGS 2620 memiliki sensitivitas yang tinggi terhadap uap larutan organik selain itu sensitif pula pada gas yang mudah terbakar seperti karbon monoksida maupun hidrogen. Karena ukurannya yang kecil TGS 2620 hanya memerlukan arus untuk mengendalikan pemanas internal sebesar 42mA. Hubungan antara hambatan sensor terhadap konsentrasi gas adalah linier pada skala logaritmik mulai dari beberapa ppm hingga beberapa ribu ppm.

3.6 Machine Learning

Machine Learning atau pembelajaran mesin merupakan bagian dari *Artificial Intelligence* atau kecerdasan buatan. *Machine Learning* adalah cabang ilmu komputer yang secara luas bertujuan untuk memungkinkan komputer untuk dapat “belajar” tanpa diprogram secara langsung. Dalam praktiknya, komputer diajarkan dengan berbasis kepada “pengalaman” yang biasanya berarti menyesuaikan dengan data dengan pendekatan statistik (Qifang, et.al, 2019).

3.6.1 *Supervised Learning*

Supervised Learning merupakan tipe dari sistem pembelajaran mesin yang menggunakan pendekatan AI untuk dilatih mengenali pola antara input data dan label output. Klasifikasi dan regresi adalah tipe dari metode ini. Data awalnya akan melatih sistem yang telah dirancang yang nanti sistem dapat memprediksi suatu data tes (Rudolf, 2018).



Gambar 3.3 Contoh Aplikasi *Supervised Learning* (Rudolf, 2018)

Dalam metode ini, terdapat beberapa algoritma yang populer seperti:

- a. K-nears neighbors
- b. Linear Regression
- c. Neural Network
- d. Support Vector Machine
- e. Logistic Regression
- f. Decision Tree dan Random Forest

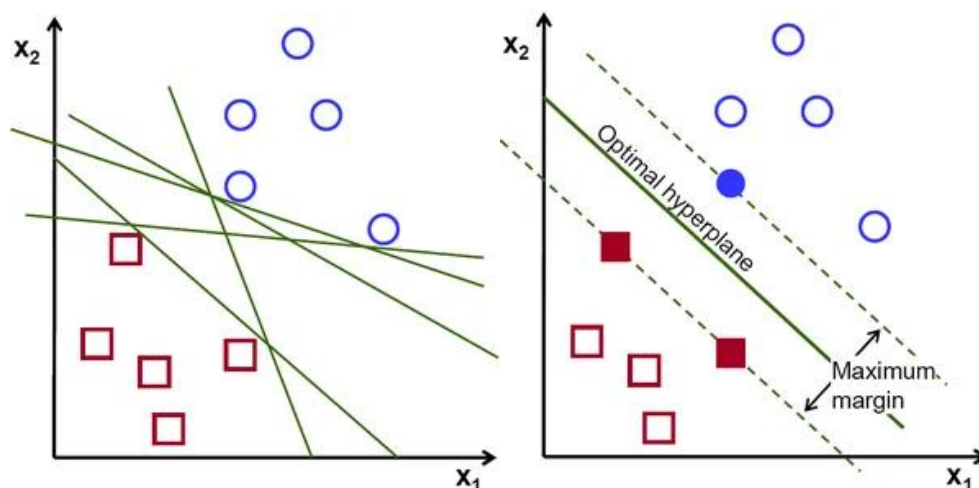
3.6.2 *Unsupervised Learning*

Unsupervised Learning adalah metode atau teknik yang digunakan dengan tidak perlu melatih algoritma komputer untuk dapat mengenali penyusunan AI. Model dirancang untuk dapat bisa belajar mandiri untuk dapat mengumpulkan informasi termasuk data yang tidak berlabel (Rudolf, 2018). Beberapa algoritma dari *Unsupervised Learning*, antara lain:

- a. *Clustering*: K-means, Hierarchical Cluster Analysis
- b. *Association rule learning*: Eclat, Apriori
- c. *Visualization and dimensionality reduction*: Kernel PCS, t-distributed, PCA

3.7 Support Vector Machine (SVM)

Support Vector Machine (SVM) adalah suatu metode klasifikasi dalam *Machine Learning* yang berfokus pada pencarian *hyperplane* dalam ruang berdimensi N (N -jumlah fitur) yang secara jelas mengklasifikasikan titik-titik data. Dalam pemisahan dua kelas titik data, ada banyak kemungkinan *hyperplane* yang bisa dipilih. Tujuannya adalah menemukan bidang yang memiliki margin maksimum, yaitu jarak maksimum antara titik data dari kedua kelas. Memaksimalkan jarak margin memberikan penguatan sehingga titik data di masa mendatang dapat diklasifikasikan dengan lebih percaya diri (Mukhopadhyay, 2018).



Gambar 3.4 Grafik Support Vector Machine (Rudolf, 2018)

Hyperplanes adalah batas keputusan yang membantu mengklasifikasikan titik data. Poin data yang jatuh di kedua sisi *hyperplane* dapat dikaitkan dengan kelas yang berbeda. Juga, dimensi *hyperplane* bergantung pada jumlah fitur. Jika jumlah fitur input adalah 2, maka *hyperplane* hanya berupa garis. Jika jumlah fitur masukan adalah 3, maka *hyperplane* menjadi bidang dua dimensi. Sulit membayangkan ketika jumlah fitur melebihi 3 (Mukhopadhyay, 2018).

3.8 Pengujian

Menurut KBBI, pengujian adalah proses, cara, dan perbuatan menguji yang memeriksa apakah sistem, baik perangkat lunak maupun perangkat keras,

berperilaku sesuai dengan yang diinginkan. Pengujian merupakan suatu rangkaian aktivitas yang dirancang dan direncanakan dan akan dilakukan secara sistematis. Pengujian adalah bagian dari proses pengembangan atau pembuatan suatu sistem. Proses pengujian dilakukan untuk mengetes seluruh sistem yang telah dibuat dan dikembangkan melalui beberapa tes dengan tujuan utama mengenai akurasi sistem dibandingkan dengan hasil nyata di lingkungan.

Sebagai pengujian dari sistem yang telah dilatih, dapat dilakukan evaluasi performa sistem dengan prediksi sebagai *classification report* dan juga evaluasi akurasi performa sistem yang telah dilatih. Dalam sistem model *machine learning* khususnya klasifikasi, terdapat metode pengujian yang umum digunakan yaitu *Confusion Matrix*.

Confusion Matrix adalah alat untuk analisa prediksi dalam algoritma *machine learning* dengan tujuan untuk mengecek performa dari klasifikasi berdasarkan model yang telah dibuat. Selain itu, *Confusion Matrix* juga dapat disebut sebagai rangkuman tabel dari prediksi benar dan salah dari suatu model klasifikasi untuk tugas klasifikasi biner (Zohreh, 2021).

3x3	<i>Predict</i>		
<i>Actual</i>	A	B	C
A	TP(A)	FP(B)	FP(C)
B	FP(A)	TP(B)	FP(C)
C	FP(A)	FP(B)	TP(C)

Gambar 3.5 Matriks Kotak *Confusion Matrix*

Dalam pengujian yang dapat dilakukan dengan metode *Confusion Matrix*, terdapat beberapa formulasi pengujian yang dapat dilakukan, yaitu:

1. Akurasi

Akurasi adalah pengukuran berapa banyak prediksi benar dari suatu model. Akurasi menjadi pengujian paling dasar untuk mengukur performa dari suatu model. Berikut merupakan persamaan rumus yang dipakai pada persamaan (3.1)

$$Accuracy = \frac{TP(A)+TP(B)+TP(C)}{Total\ Sample} \quad (3.1)$$

2. Presisi

Presisi dapat memberikan hasil pengukuran berapa banyak kasus yang diprediksi benar dan bernilai positif. Hal ini dapat menentukan apakah model dapat diandalkan atau tidak. Presisi berguna jika *False Positive* lebih diperhatikan daripada *False Negative*. Persamaan ini ditunjukkan sebagai pada persamaan (3.2, 3.3, 3.4)

$$\bullet \text{ Precision}(A) = \frac{TP(A)}{TP(A)+FP(A)} \quad (3.2)$$

$$\bullet \text{ Precision}(B) = \frac{TP(B)}{TP(B)+FP(B)} \quad (3.3)$$

$$\bullet \text{ Precision}(C) = \frac{TP(C)}{TP(C)+FP(C)} \quad (3.4)$$

3. Recall (Sensitivity)

Recall dapat memberikan informasi berapa banyak kasus positif aktual yang dapat diprediksi dengan benar. Hal ini berguna ketika *False Positive* lebih diperhatikan dibanding dengan *False Negative*. *Recall* yang tinggi akan menginterpretasikan akurasi keseluruhan yang rendah. Persamaan ini ditunjukkan sebagai pada persamaan (3.5, 3.6, 3.7)

$$\bullet \text{ Recall}(A) = \frac{TP(A)}{TP(A)+FN(A)} \quad (3.5)$$

$$\bullet \text{ Recall}(B) = \frac{TP(B)}{TP(B)+FN(B)} \quad (3.6)$$

$$\bullet \text{ Recall}(C) = \frac{TP(C)}{TP(C)+FN(C)} \quad (3.7)$$

4. F1-Score

F1-Score adalah rata-rata harmonik dari Presisi dan *Recall*, *F1-Score* memberikan gagasan gabungan tentang kedua matriks ini. Ini maksimum ketika presisi sama dengan *recall*. Ketika model yang dibuat kurang baik dari nilai uji pada presisi dan *recall*, *F1-Score* digunakan dalam kombinasi dengan matriks evaluasi lain yang dapat memberikan gambaran lengkap

dari hasil. Persamaan ini ditunjukkan sebagai pada persamaan (3.8, 3.9, 3.10)

$$\bullet \quad FI - Score(A) = \frac{2 * (Presisi(A) * Recall(A))}{(Presisi(A) + Recall(A))} \quad (3.8)$$

$$\bullet \quad FI - Score(B) = \frac{2 * (Presisi(B) * Recall(B))}{(Presisi(B) + Recall(B))} \quad (3.9)$$

$$\bullet \quad FI - Score(C) = \frac{2 * (Presisi(C) * Recall(C))}{(Presisi(C) + Recall(C))} \quad (3.10)$$

BAB IV

METODE PENELITIAN

4.1 Analisis Sistem

Sistem identifikasi kematangan *roasting* kopi dilakukan untuk mengklasifikasi tingkat kematangan kopi berdasarkan level tingkat *roasting* yaitu *light*, *medium*, dan *dark*. Pada deteksi gas biji kopi digunakan perangkat *e-nose* yang terdiri dari sensor gas larik untuk membaca nilai gas pada saat *roasting* kopi berlangsung. Sensor gas larik terdiri dari 8 sensor yaitu MQ135, MQ136, MQ137, MQ138, MQ2, MQ3, TGS822 dan TGS2620. Proses pengambilan data dimulai dengan meroasting biji kopi pada tingkat kematangan yang berbeda, yaitu *light*, *medium* dan *dark*. Setelah proses *roasting*, biji kopi yang telah di *roasting* akan diambil sebagai sampel untuk pengukuran aroma menggunakan *E-Nose*. Sensor-sensor tersebut akan mendeteksi dan mengukur perubahan dalam komposisi gas yang dihasilkan oleh aroma kopi pada masing-masing tingkat kematangan *roasting*. Selanjutnya, respons sensor-sensor terhadap aroma kopi pada berbagai tingkat kematangan akan direkam dan dikumpulkan sebagai data aroma. Data ini akan digunakan dalam tahap pra-pemrosesan dan algoritma SVM untuk mengklasifikasikan tingkat kematangan *roasting* kopi menjadi *light*, *medium*, dan *dark* berdasarkan respons aroma yang terdeteksi oleh *E-Nose*.

4.2 Alat dan Bahan

Penelitian ini menggunakan komponen yang ditunjukkan pada Tabel Bahan dan Tabel Alat untuk membuat sebuah alat *roasting* kopi yang dapat mengidentifikasi tingkat kematangan kopi. Untuk itu, diperlukan beberapa perangkat, seperti pada Tabel 4. 1 dan Tabel 4. 2

Tabel 4. 1 Daftar Alat

No	Alat	Fungsi
1	Mini PC M6 8/256GB SSD Intel JasperLake N5105, Clock 2.0 GHz Up to 2.9Ghz GPU: 16EU Intel Graphics	Perangkat untuk menjalankan proses penelitian berbasis perangkat lunak

Tabel 4. 2 Daftar Alat (lanjutan)

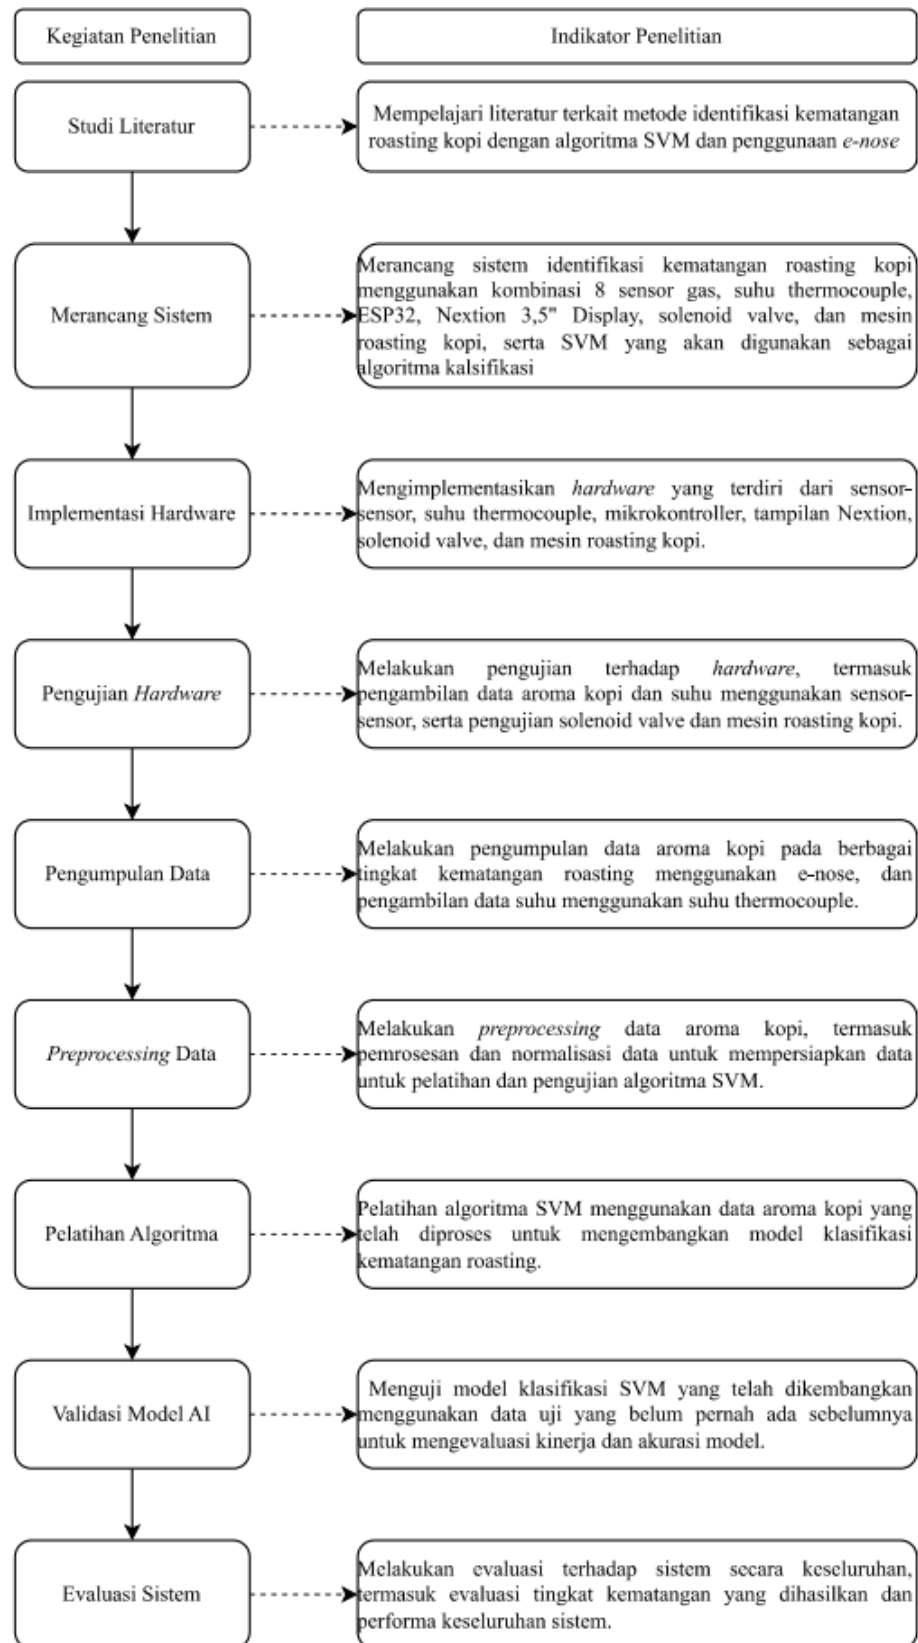
2	Python 3.8	Bahasa pemrograman untuk menjalankan segala proses pemrograman pembuatan dan pelatihan sistem
4	<i>Google Colab</i>	<i>Text editor</i> untuk menuliskan naskah program dalam pembuatan dan pelatihan sistem klasifikasi
5	<i>VS Code</i>	<i>Text editor</i> untuk menuliskan naskah program dalam pengujian sistem klasifikasi
6	Mesin Roasting Kopi	Digunakan untuk melakukan proses roasting pada biji kopi.

Tabel 4.3 Daftar Bahan

No	Nama	Fungsi
1	Mikrokontroler ESP32	Mengendalikan dan memproses data dari sensor-sensor, menghubungkan dengan komponen lainnya
2	Nextion 3,5" Display	Menampilkan informasi dan hasil identifikasi kematangan roasting kopi
3	Sensor Suhu Thermocouple	Sensor Suhu Thermocouple
4	Solenoid Valve	Mengontrol aliran udara atau gas ke dalam sistem untuk mengatur kondisi lingkungan saat pengambilan data aroma
5	Sensor MQ135	Mendeteksi gas NH ₃ , CO ₂ , dan alkohol dalam aroma kopi
6	Sensor MQ136	Mendeteksi gas NH ₃ , NO _x , dan senyawa nitrogen dalam aroma kopi
7	Sensor MQ137	Mendeteksi gas NH ₃ , NO _x , dan amonia dalam aroma kopi
8	Sensor MQ138	Mendeteksi gas formaldehida dan alkohol dalam aroma kopi
9	Sensor MQ2	Mendeteksi gas LPG, propana, metana, dan hidrogen dalam aroma kopi
10	Sensor MQ3	Mendeteksi gas alkohol dalam aroma kopi
11	Sensor TGS822	Mendeteksi gas hidrogen sulfida (H ₂ S) dan senyawa sulfur dalam aroma kopi
12	Sensor TGS2620	Mendeteksi gas amonia (NH ₃) dan senyawa nitrogen dalam aroma kopi

4.3 Tahapan Penelitian

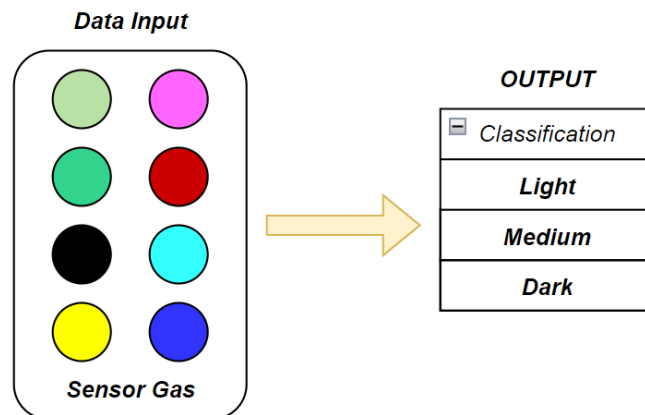
Penelitian ini memerlukan beberapa tahapan yang terbagi seperti yang ditunjukkan pada Gambar 4.1.



Gambar 4.1 Tahap Penelitian

4.4 Rancangan Sistem

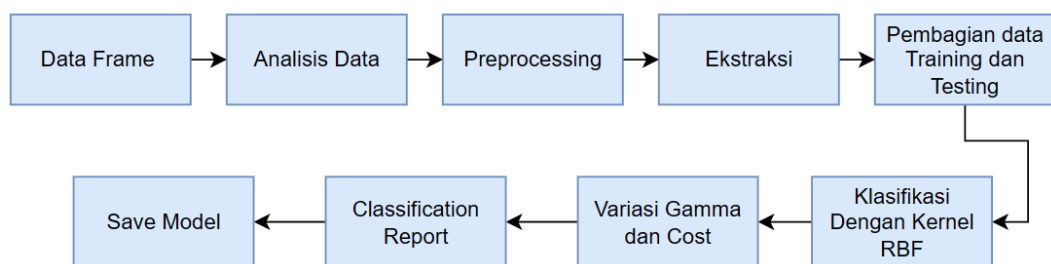
Terdapat dua komponen penting dalam sistem yang akan dibangun yaitu sistem perangkat keras sebagai media dalam proses akuisisi data dan sistem perangkat lunak yang meliputi perancangan, pelatihan, dan pengujian sistem klasifikasi berbasis *Supervised Learning*.



Gambar 4.2 Rancangan Input Data

Gambar 4.2 menjelaskan rancangan input data menggunakan 8 sensor gas yang terdiri dari MQ *series* dan TGS *series*. Data dari pembacaan sensor akan di klasifikasi sehingga menghasilkan 3 kelas output tingkat kematangan kopi yaitu *light*, *medium*, dan *dark*.

4.4.1 Rancangan Klasifikasi SVM



Gambar 4.3 Rancangan Klasifikasi SVM

Gambar 4.3 menjelaskan rancangan klasifikasi yang dilakukan pada penelitian .

1. Pembacaan Data dan Analisis Awal

Pada tahap ini, dataset dalam format .csv dibaca dan dimuat ke dalam DataFrame menggunakan pustaka Pandas di Python. Proses ini mencakup langkah-

langkah seperti memuat dataset ke dalam struktur data tabular, mengeksplorasi beberapa baris pertama atau terakhir dari dataset untuk memahami strukturnya, dan mengecek tipe data dari setiap kolom. Selain itu, analisis awal dilakukan untuk memeriksa distribusi nilai dari setiap fitur, mengeksplorasi korelasi antar variabel, dan mengidentifikasi potensi outlier atau data yang hilang. Analisis awal ini memberikan wawasan awal tentang karakteristik data yang akan diolah dan membantu dalam pemahaman konteks masalah.

2. Pra-pemrosesan Data

Setelah dataset dimuat, langkah selanjutnya adalah melakukan pra-pemrosesan data. Pra-pemrosesan data adalah tahap penting dalam persiapan data sebelum dilakukan pemodelan. Pada tahap ini, normalisasi data dilakukan untuk mengubah rentang nilai dari 0 hingga 1. Normalisasi ini penting untuk memastikan bahwa semua fitur memiliki skala yang serupa, sehingga tidak ada fitur yang mendominasi proses pembelajaran. Selain itu, tahap pra-pemrosesan ini juga mencakup penanganan nilai yang hilang, encoding variabel kategori menjadi bentuk numerik, dan pemilihan fitur yang relevan. Langkah-langkah ini membantu dalam meningkatkan kualitas dan kelengkapan dataset sehingga model yang dibangun dapat memberikan hasil yang lebih baik.

3. Ekstraksi Fitur

Setelah pra-pemrosesan data dilakukan, langkah selanjutnya adalah melakukan ekstraksi fitur. Ekstraksi fitur adalah proses identifikasi dan pilihan fitur-fitur yang paling informatif dari dataset. Fitur-fitur ini akan digunakan sebagai input untuk model klasifikasi. Proses ini melibatkan pemilihan fitur-fitur yang paling relevan dengan tujuan akhir pengklasifikasian komponen gas aroma roasting kopi. Dalam konteks ini, ekstraksi fitur dapat mencakup teknik-teknik seperti reduksi dimensi, pemilihan fitur berbasis statistik, atau penggunaan domain knowledge untuk mengekstraksi fitur-fitur yang paling informatif.

4. Pembagian Data Training dan Testing

Data dibagi menjadi dua subset: data latih dan data uji. Data latih digunakan untuk melatih model klasifikasi, sedangkan data uji digunakan untuk menguji kinerja model yang dilatih. Pembagian ini penting untuk menghindari overfitting

dan memastikan generalisasi yang baik dari model. Dengan membagi dataset menjadi dua bagian ini, dapat dipastikan bahwa model dapat mempelajari pola umum dari data tanpa mengorbankan kemampuan umumnya. Selain itu, pembagian data ini juga memungkinkan evaluasi yang obyektif terhadap kinerja model pada data yang belum pernah dilihat sebelumnya.

5. Klasifikasi dengan Kernel RBF

Metode Support Vector Machine (SVM) dipilih sebagai algoritma klasifikasi untuk sistem ini. SVM adalah salah satu algoritma pembelajaran mesin yang paling umum digunakan untuk klasifikasi dan regresi. Pada tahap ini, model SVM dilatih menggunakan data latih yang telah diproses sebelumnya. Penggunaan kernel RBF dalam SVM memungkinkan model untuk menangani data yang bertumpuk dan non-linear. Proses pelatihan ini melibatkan penyetelan parameter penting seperti cost dan gamma untuk memperoleh model yang optimal.

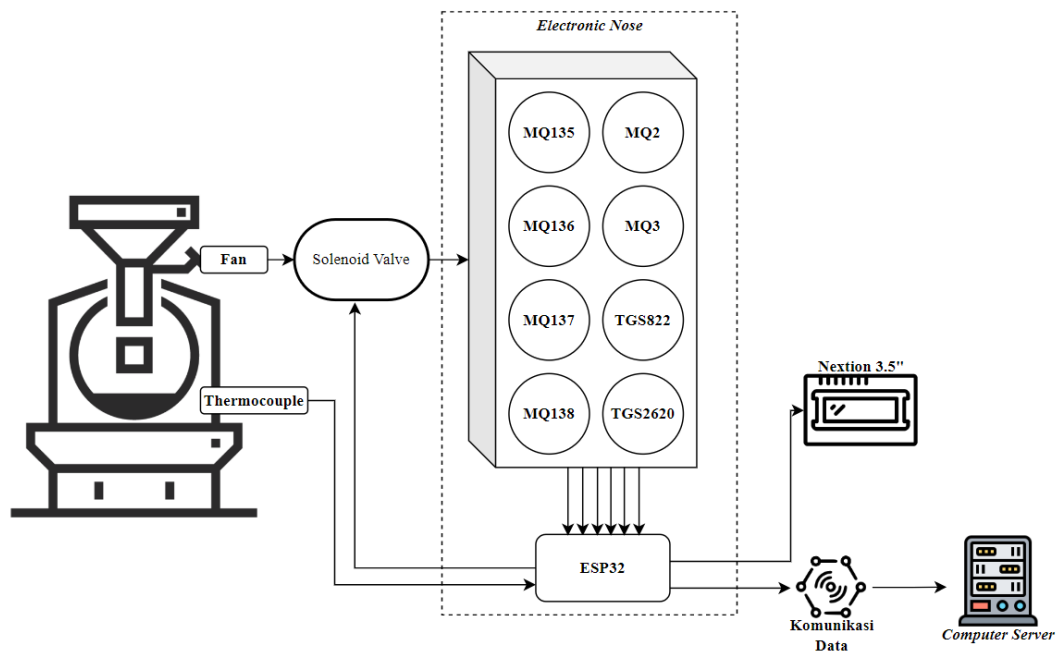
6. Classification Report

Pada tahap ini, dataset dalam format .csv dibaca dan dimuat ke dalam DataFrame menggunakan pustaka Pandas di Python. Proses ini mencakup langkah-langkah seperti memuat dataset ke dalam struktur data tabular, mengeksplorasi beberapa baris pertama atau terakhir dari dataset untuk memahami strukturnya, dan mengecek tipe data dari setiap kolom. Selain itu, analisis awal dilakukan untuk memeriksa distribusi nilai dari setiap fitur, mengeksplorasi korelasi antar variabel, dan mengidentifikasi potensi outlier atau data yang hilang. Analisis awal ini memberikan wawasan awal tentang karakteristik data yang akan diolah dan membantu dalam pemahaman konteks masalah.

4.4.2 Rancangan Perangkat Keras

Perangkat keras berperan sebagai alat pengambilan data berupa data sensor gas. Sensor gas digunakan untuk mendeteksi aroma kopi pada tahap *roasting*. Sensor suhu *thermocouple* digunakan untuk mengukur suhu pada mesin *roasting* kopi. Mikrokontroler ESP32 berfungsi sebagai pusat pengendalian, mengumpulkan data dari sensor-sensor dan mengatur operasi mesin *roasting* kopi. Nextion 3,5" *Display* yang memungkinkan pengguna memantau dan mengontrol proses *roasting*

dengan mudah. Selain itu, *solenoid valve* digunakan untuk mengendalikan aliran udara pada mesin kopi. Data *roasting* yang diperoleh kemudian dikirim menuju komputer server untuk dilakukan klasifikasi tingkat kematangan kopi. Gambar hasil rancangan perangkat keras dapat dilihat pada Gambar 4.4.



Gambar 4.4 Rancangan Sistem Perangkat Keras

4.4.3 Proses Akuisisi dan Pengambilan Data

Proses akuisisi data dalam identifikasi kematangan *roasting* kopi menggunakan algoritma SVM berbasis mesin roasting kopi dengan *e-nose* melibatkan langkah-langkah seperti pengaturan perangkat keras, persiapan sampel kopi, pemasangan sensor, pengambilan data aroma menggunakan *e-nose*, pengukuran suhu menggunakan suhu *thermocouple*, dan penyimpanan data aroma kopi dan suhu. Selama proses *roasting*, sensor-sensor akan mendeteksi aroma kopi yang dihasilkan, sementara suhu *thermocouple* akan mengukur suhu pada setiap tahap *roasting*. Data aroma kopi dan suhu yang terkumpul akan dibagi dua menjadi data latih (*training data*) yang digunakan untuk melatih model SVM dan data uji (*testing data*) untuk menguji performa sistem yang telah dilatih untuk menghindari overfitting, di mana model mementingkan “hafalan” data latih dan tidak bisa mengklasifikasi data baru. Selanjutnya dilakukan *preprocessing* data untuk seluruh

data yang sudah diambil, pelatihan algoritma dan validasi model untuk data latih, terakhir pengujian data menggunakan data latih yang sudah diproses ke dalam model dan data uji yang sudah dilakukan *preprocessing* sebelumnya, sehingga sistem dapat mengidentifikasi kematangan *roasting* kopi dengan akurasi yang tinggi berdasarkan data yang telah diakuisisi.

4.5 Rancangan Analisis

Penelitian tentang kinerja pemodelan klasifikasi harus dilakukan untuk menentukan kualitas dan kelemahan model yang dibuat. Salah satu cara untuk mengukur kinerja suatu model adalah metode holdout. Data akan dibagi menjadi dua bagian dengan metode ini: data pelatihan dan data tes. Metode holdout bergantung pada pembagian data testing dan training secara acak, tetapi biasanya perbandingan antara data testing dan training, yaitu 8:2.

4.5.1 Confusion Matrix

Analisis penelitian ini menggunakan confusion matrix untuk mengklasifikasikan dua kelas atau lebih menggunakan metode Support Vector Machine. Confusion Matrix dapat merepresentasikan klasifikasi yang benar dan salah pada setiap kelas. Pada matriks konfusi, hasil proses klasifikasi direpresentasikan dengan istilah yaitu true positive (TP), true negative (TN), false positive (FP), dan false negative (FN).

4.5.2 Akurasi

Pemodelan klasifikasi dapat diukur kinerjanya dengan menentukan seberapa baik nilai akurasi suatu model. Akurasi dapat ditentukan dengan menggunakan Persamaan (4.1).

$$\text{Akurasi} = \frac{TP+TN}{(TP+TN+FP+FN)} \times 100\% \quad (4.1)$$

True Positive (TP) merupakan data positif yang terindikasi benar. True Negative merupakan data negatif merupakan data negatif yang terindikasi benar. False Positive (FP) merupakan data negatif namun terindikasi sebagai data positif. False Negatif (FN) merupakan data positif yang terindikasi sebagai data negatif.

4.5.3 Presisi

Pemodelan klasifikasi dapat diukur kinerjanya dengan menentukan tingkat presisi dalam mengklasifikasikan suatu kelas. Presisi merupakan rasio prediksi True Positive dibandingkan dengan keseluruhan hasil prediksi positif. Presisi dapat ditentukan dengan menggunakan Persamaan (4.2).

$$\text{Presisi} = \frac{TP}{(TP+FP)} \times 100\% \quad (4.2)$$

4.5.4 Recall

Recall mengukur seberapa baik model dapat mengidentifikasi dan mengklasifikasikan semua data yang relevan dalam kelas tertentu. Secara khusus, recall menghitung persentase data positif yang benar-benar diidentifikasi sebagai positif oleh model. Recall dapat dihitung menggunakan Persamaan (4.3).

$$\text{Recall} = \frac{TP}{(TP+FN)} \times 100\% \quad (4.3)$$

4.5.4 Spesifitas

Spesifitas mengukur seberapa baik model dapat mengidentifikasi dan mengklasifikasikan semua data yang tidak relevan dari kelas tertentu. Secara khusus, spesifitas menghitung persentase data negatif yang benar-benar diidentifikasi sebagai negatif oleh model. Specificity dapat dihitung menggunakan Persamaan (4.4).

$$\text{Spesifitas} = \frac{TN}{(TN+FP)} \times 100\% \quad (4.4)$$

4.6 Pengujian Sistem

Model SVM dilatih menggunakan data latih yang terdiri dari vektor fitur yang dihasilkan melalui sensor MOS dan label kematangan kopi yang sesuai, untuk menemukan garis pembatas (hyperplane) terbaik dalam ruang fitur sensor MOS yang dapat memisahkan kelas-kelas kematangan yang berbeda. Selanjutnya model tersebut akan diuji dengan data uji yang sudah disiapkan. Performa sistem akan dievaluasi melalui perhitungan matriks evaluasi seperti akurasi, presisi, recall, dan F1-score. Akurasi merupakan proporsi klasifikasi yang benar dari seluruh data uji,

Presisi digunakan sebagai ukuran seberapa banyak hasil positif yang diprediksi oleh model yang benar (*True Positive*), recall mengukur seberapa baik model mengidentifikasi hasil yang positif, serta F1-score yakni rata-rata harmonik presisi dan recall.

Terakhir untuk meningkatkan performa sistem, dapat dilakukan pengujian sensitivitas. Pengujian sensitivitas dilakukan dengan memvariasikan parameter-parameter SVM seperti parameter kernel (*linear, polynomial, atau radial basis function*), C (parameter penalti untuk kesalahan klasifikasi), dan gamma (koefisien kernel untuk kernel non-linear). Variasi parameter tersebut bertujuan mencari performa sistem yang optimal, serta akurasi yang lebih tinggi dalam meningkatkan kemampuan sistem untuk mengklasifikasi tingkat kematangan kopi dengan tepat.

Sistem klasifikasi menggunakan algoritma SVM untuk identifikasi kematangan *roasting* kopi melibatkan beberapa langkah pengujian yang mencakup pembagian data menjadi data latih dan data uji, pelatihan model SVM menggunakan data latih, evaluasi performa sistem menggunakan data uji dengan menghitung matrik evaluasi seperti akurasi, presisi, *recall*, dan F1-score, serta pengujian sensitivitas dengan memvariasikan parameter-parameter SVM. Melalui serangkaian pengujian ini, sistem dievaluasi untuk mengukur kemampuannya dalam mengklasifikasikan tingkat kematangan kopi dengan tepat. Jika hasil akurasi yang didapatkan kurang dari 90%, maka akan dilakukan penyesuaian pada parameter pelatihan yang akan dilakukan kembali hingga angka akurasi yang didapatkan di atas angka 90%.

BAB V

IMPLEMENTASI


5.1 Implementasi Perangkat Keras

Penelitian ini menggunakan perangkat keras, aktuator dan perangkat lunak untuk mengimplemntasikan sistem yang dibuat.

5.1.1 Implementasi Elektronik dan aktuator


Proses pembuatan rangkaian elektronik dan integrasinya dengan aktuator serta display didukung oleh software Eagle Autodesk. Langkah awal dilakukan dengan pembuatan skematik, diikuti oleh desain PCB menggunakan sistem embed untuk memastikan ukurannya lebih kecil, sehingga lebih compact dan portable. Dalam rangkaian elektronik ini, sensor-sensor gas seperti dihubungkan ke IC ADS1115 sebagai pembaca data sensor gas yang kemudian akan dikirim ke ESP32 melalui komunikasi I2C. Selanjutnya, rangkaian USB to TTL menggunakan IC FT232RL yang terhubung dengan ESP32 digunakan untuk komunikasi data dengan miniPC.

Pada bagian aktuator, vacuum pump menggunakan driver mosfet IRFZ44 yang dihubungkan pada pin PWM ESP32 untuk mengatur kecepatan vacuum pumpnya. Untuk menjaga kesesuaian level logika, semua data yang menggunakan logika 5V, baik dari ADS1115, I2C, maupun Serial pada Display Nextion 5”, akan dikonversi menjadi logika 3.3V menggunakan IC TXS0108EPWR. Hasil dari proses skematik rangkaian tersebut dapat dilihat pada Gambar 5.1, Gambar 5.2, Gambar 5.3, Gambar 5.4, dan Gambar 5.5.

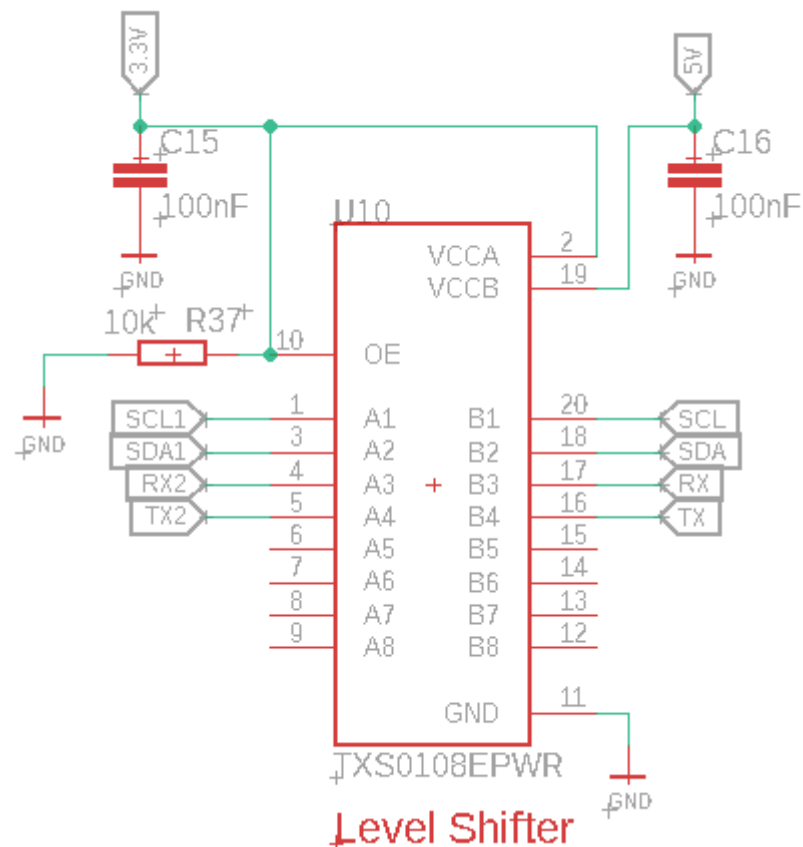


The diagram illustrates a USB to TTL module. It consists of a USB4105-GF-A chip connected to a USB port (A5-A8, D+, D-). The module includes a CH340G and an FT232RL. It has two LEDs (LED1, LED2) and two push buttons (R1, R2). Power is supplied via a +5V and +3V3 pins. The module is labeled "USB TO TTL".

Gambar 5.3 Rangkaian USB to TTL




Gambar 5.4 Rangkaian Aktuator Vacuum Pump



Gambar 5.5 Rangkaian Level Shifter TXS0108EPWR

Setelah Dilakukan pembuatan skematik, tahapan selanjutnya pembuatan layout PCB untuk mengintegrasikan semua komponen elektronik, aktuator, dan juga display. Proses pembuatan layout PCB menggunakan bantuan software Eagle PCB. Hasil layout PCB dan implementasi PCB dapat dilihat pada Gambar 5.6 dan Gambar 5.7.



Gambar 5.6 Hasil layout PCB




Gambar 5.7 Hasil Implementasi layout PCB

5.1.2 Implementasi Mekanik

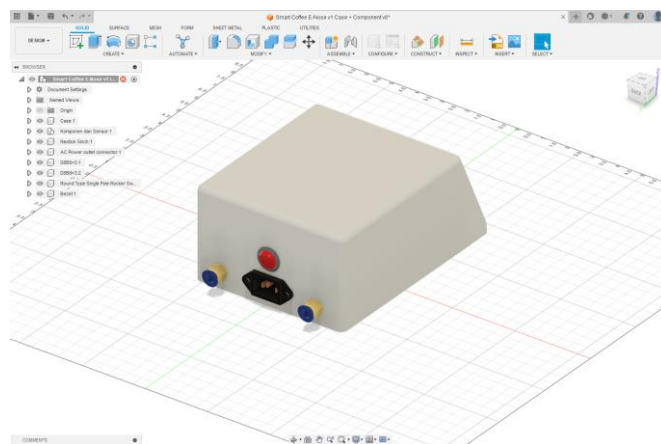
Proses pembuatan case alat menggunakan bantuan software Fusion 360 Autodesk dimulai dengan memperhatikan kebutuhan dan spesifikasi alat yang akan dibuat. Dengan memanfaatkan fitur desain 3D yang disediakan oleh Fusion 360, berbagai komponen seperti komponen elektronik, aktuator, dan chamber dapat ditempatkan secara optimal sesuai dengan fungsi dan kebutuhan alat. Selain itu,

dalam proses desain, nilai fungsi dan kemudahan dalam pemakaian alat menjadi fokus utama, sehingga pengguna dapat dengan mudah mengoperasikan alat dengan efisien. Selain itu, bahan filament ABS dipilih untuk pembuatan case alat karena tahan panas, sehingga mampu menahan suhu tinggi saat proses roasting biji kopi, yang memastikan keamanan dan kinerja optimal selama penggunaan.

Hasil dari implementasi desain case alat menggunakan Fusion 360 Autodesk dapat dilihat pada Gambar 5.8 dan Gambar 5.9. Desain 3D memberikan visualisasi yang jelas dan detail mengenai bagaimana setiap komponen disusun dan diposisikan di dalam case alat. Selain itu, dengan menggunakan bahan filament ABS yang tahan panas, case alat dapat menjamin keamanan dan kinerja yang optimal saat proses roasting biji kopi.



Gambar 5.8 Tampak perspektif



Gambar 5.9 Tampak belakang desain case alat



Gambar 5.10 Hasil implementasi desain case alat tampak perspektif

5.2 Implementasi Akuisisi Data Sensor

Tahapan akuisisi data sensor menggunakan software visual Studio Code untuk membaca input sensor gas melalui ADS1115. Proses ini dilakukan pemrograman pada mikorokntroller ESP32. Menggunakan library ADS1115 untuk berkomunikasi dengan ADS1115 melalui I2C dengan Alamat 0x48. Pada fungsi loop(), dilakukan pembacaan nilai ADC (Analog to Digital Converter) dari masing-masing channel yang terhubung ke sensor gas. Menggunakan syntax readADC_SingleEnded() untuk membaca nilai ADC dari setiap channel. Setiap sensor gas terhubung ke saluran ADC tertentu pada ADS1115. Syntax yang digunakan dapat dilihat pada Gambar 5.12.

```

1 | #include "ADS1X15.h"
2 | #include <Wire.h>
3 | {
4 |   adc_mq135 = ads1.readADC(ADS1_CHAN_MQ135);
5 |   adc_mq136 = ads2.readADC(ADS2_CHAN_MQ136);
6 |   adc_mq137 = ads1.readADC(ADS1_CHAN_MQ137);
7 |   adc_mq138 = ads1.readADC(ADS1_CHAN_MQ138);
8 |   adc_mq2   = ads2.readADC(ADS2_CHAN_MQ2);
9 |   adc_mq3   = ads1.readADC(ADS1_CHAN_MQ3);
10|   adc_tgs822 = ads2.readADC(ADS2_CHAN_TGS822);
11|   adc_tgs2620 = ads2.readADC(ADS2_CHAN_TGS2620);
12| }

```

Gambar 5.11 Syntax Code akuisisi data sensor

5.2.1 Record Data sensor Gas

Perekaman data sensor gas dilakukan menggunakan menggunakan program python dengan membaca nilai analog dari rentang 0 hingga 65.536 yang

direpresentasikan sebagai bilangan decimal antar 0 hingga 5V. Program `listen_sensor()` berfungsi untuk membaca data sensor gas dari hardware enose melalui komunikasi serial menggunakan objek `serial_handler` `read()`, Data yang di ambil kemudian diubah menjadi format JSON menggunakan fungsi `json.dumps(data)`. Berikut syntax yang digunakan untuk merecord data sensor gas dan dihasilkan output .txt dapat dilihat pada Gambar 5.13.

```

1 | def listen_sensor():
2 |     global is_run
3 |     while(is_run):
4 |         try:
5 |             t = datetime.now()
6 |             data = serial_handler.read()
7 |             data["time"] = str(t)
8 |             data["status"] = str(status)
9 |
10 |             # print(data)
11 |
12 |             out = json.dumps(data)
13 |
14 |             # print(filename)
15 |             # break
16 |
17 |             f = open(filename, "+a")
18 |             f.write(out + '\n')
19 |             f.close()
20 |
21 |         except Exception as e:
22 |             print(e)

```

Gambar 5.12 Program record data sensor gas

5.2.2 Visualisasi data sensor gas dalam bentuk grafik pada display Nextion

Data sensor gas yang telah dibaca oleh mikrokontroller akan ditampilkan pada display nextion dalam bentuk grafik, digunakan pemrograman menggunakan visual studio Code. Syntax yang digunakan `graphCallback()` digunakan untuk memperbarui data pada grafik yang ditampilkan di layar nextion. Sedangkan fungsi `sendWave(int cid int chan int val)` untuk mengirim data gelombang (waveform) ke layar Nextion dan menerima tiga parameter `cid` (ID komponen), `chan` (saluran), dan `val` (nilai). Untuk syntak pemrogramannya dapat dilihat pada Gambar 5. 14.

```

1 | void graphCallback() {
2 |     #if USE_NEXTION_GRAPH
3 |     sendWave(NEX_WAVE1_CID, NEX_WAVE1_CHAN_MQ135, (int)(ADC16TO8 * adc_mq135));
4 |     sendWave(NEX_WAVE1_CID, NEX_WAVE1_CHAN_MQ136, (int)(ADC16TO8 * adc_mq136));
5 |     sendWave(NEX_WAVE1_CID, NEX_WAVE1_CHAN_MQ137, (int)(ADC16TO8 * adc_mq137));
6 |     sendWave(NEX_WAVE1_CID, NEX_WAVE1_CHAN_MQ138, (int)(ADC16TO8 * adc_mq138));
7 |     sendWave(NEX_WAVE2_CID, NEX_WAVE2_CHAN_MQ2, (int)(ADC16TO8 * adc_mq2));
8 |     sendWave(NEX_WAVE2_CID, NEX_WAVE2_CHAN_MQ3, (int)(ADC16TO8 * adc_mq3));
9 |     sendWave(NEX_WAVE2_CID, NEX_WAVE2_CHAN_TGS822, (int)(ADC16TO8 * adc_tgs822));
10 |    sendWave(NEX_WAVE2_CID, NEX_WAVE2_CHAN_TGS2620, (int)(ADC16TO8 * adc_tgs2620));
11 |    #endif
12 | }
13 |

```

```

14| void sendWave(int cid, int chan, int val){
15|     if(val > 254) val = 254;
16|     String msg = "add " +
17|         String(cid) + "," +
18|         String(chan) + "," +
19|         String(val);
20|     s
21|     nexSerial.print(msg);
22|     nexSerial.write(0xFF);
23|     nexSerial.write(0xFF);
24|     nexSerial.write(0xFF);
25|     delay(50);
26| }

```



Gambar 5.13 Syntax Pemrograman visualisasi pada Nextion.

5.3 Analisis Dataset

Data yang digunakan pada penelitian ini diambil secara langsung pada saat proses roasting kopi menggunakan hardware e-nose dengan berbagai sensor gas yang memiliki karakteristik deteksi aroma yang berbeda. Pada saat pengambilan dataset terdapat gas aroma dengan jenis yang berbeda diantaranya adalah aroma gas saat unclass atau saat masih bean, light roast, medium roast, dan dark roast, dan juga udara normal.

Data yang dihasilkan dari respons beberapa sensor terhadap aroma gas yang ditangkap selama proses roasting kopi disimpan dalam format teks atau.txt. Respon dari masing-masing sensor terdiri dari sinyal dalam bentuk tegangan (mV) yang diambil selama proses roasting kopi. Sinyal yang dihasilkan dari gas yang ditangkap oleh sensor diubah menjadi besaran tegangan. Untuk proses normalisasi data, hasil bacaan sensor akan langsung dikirim ke miniPC.

5.3.1 Implementasi Pra Processing

Penelitian ini menggunakan normalisasi data, yang merupakan proses menskalakan kumpulan nilai yang lebih besar dan lebih kecil menjadi skala yang sama. Dengan demikian, proses normalisasi ini dapat mengurangi kumpulan nilai yang terlalu besar dan terlalu kecil.

Proses normalisasi pada penelitian ini membandingkan beberapa metode scaling yaitu *Before Scalling*, *After Robust Scalling*, *After Standard Scalling*, dan *Afrer Min-Max Scalling*. Preprocessing dilakukan dengan menggunakan library scikit-learn atau sklearn dengan melakukan import preprocessing. Selain itu, preprocessing mencakup scaling atau penskalaan. Ada tiga jenis penskalaan yang

digunakan oleh program ini: robust, standard, dan minmax. Fitur penskalaan robust menghapus median dan menskalakan data sesuai dengan jangkauan kuartil. Fitur penskalaan standar menormalisasi data agar tidak terlalu berbeda dari rata-rata, menghilangkan rata-rata daripada rata-rata. Fitur penskalaan minmax melakukan penskalaan dan menerjemahkan masing-masing fitur secara terpisah sehingga berada dalam rentang yang ditetapkan. Berikut merupakan Syntak pemrograman normalisasi yang dapat dilihat pada Gambar 5.15

```

1 | scaler = StandardScaler()
2 | X_train = scaler.fit_transform(X_train)
3 | X_test = scaler.transform(X_test)
4 |
5 | robust_scaler = RobustScaler()
6 | X_train_robust = robust_scaler.fit_transform(X_train)
7 | X_test_robust = robust_scaler.transform(X_test)
8 |
9 | min_max_scaler = MinMaxScaler()
10| X_train_min_max = min_max_scaler.fit_transform(X_train)
11| X_test_min_max = min_max_scaler.transform(X_test)

```

Gambar 5. 14 Syntak Pemrograman Normalisasi

Untuk mempersiapkan dataset untuk penggunaan machine learning, potongan kode di atas melakukan penskalaan fitur, yang merupakan langkah penting dalam pra-pemrosesan data. Ini dilakukan untuk memastikan bahwa variabel-variabel dalam dataset memiliki skala yang sebanding atau setara, sehingga model machine learning dapat beroperasi dengan baik.

Pertama, fitur-fitur dalam dataset latihan (`X_train`) diskalakan dengan menggunakan `StandardScaler`, yang menghilangkan rata-rata dari setiap fitur dan menskalakannya ke varians unit. Syntax yang digunakan adalah `scaler.fit_transform(X_train)`, dan metode `fit_transform()` menghitung statistik yang diperlukan dari dataset latihan, termasuk varians dan rata-rata, dan kemudian melakukan transformasi pada dataset latih.

5.3.2 Implementasi Ekstraksi Ciri

Implementasi ekstraksi ciri dilakukan dengan melakukan labeling pada setiap class hasil roasting kopi yang terdiri dari dari light, medium dan dark. Ekstraksi ciri melakukan eliminasi dari sensor yang dipakai yaitu MQ135, MQ136, MQ137, MQ138, MQ2, MQ3, TGS822, dan TGS2620 sehingga yang digunakan adalah sensor yang merepresentasikan dari class hasil roasting kopi yang

dihasilkan. Hasil ekstraksi ciri dilakukan menggunakan software Excel yang akan ditampilkan dalam bentuk grafik yang mewakili setiap class hasil roasting kopi.

5.4 Implementasi Klasifikasi SVM

Klasifikasi hasil roasting kopi dilakukan menggunakan *Support Vector Machine* menggunakan *google colab*. Proses klasifikasi dilakukan menggunakan beberapa library pada gambar 5.16.

```
1 | import pandas as pd
2 | from sklearn.model_selection import train_test_split, GridSearchCV
3 | from sklearn.preprocessing import StandardScaler
4 | from sklearn.svm import SVC
5 | from sklearn.metrics import accuracy_score, confusion_matrix, f1_score,
  recall_score, precision_score
6 | from matplotlib import pyplot as plt
7 | import seaborn as sns
8 | import numpy as np
```

Gambar 5.15 Library training dan testing

Beberapa library Python dapat dilihat pada Gambar 5.16 sangat penting untuk proses melakukan klasifikasi menggunakan Support Vector Machine (SVM). Pertama, library pandas digunakan untuk mengatur dan menganalisis data. Pandas membantu dalam membaca dataset dari file CSV dan menghapus kolom yang tidak diperlukan. Selain itu, fungsi `train_test_split` yang ada pada `sklearn.model_selection` digunakan untuk pembagian dataset menjadi subset pelatihan dan pengujian. Fungsi ini sangat penting untuk mengevaluasi kinerja model pada data yang tidak dilihat sebelumnya. Kemudian, `GridSearchCV` dari `sklearn.model_selection` digunakan untuk menemukan parameter model SVM terbaik dengan melakukan pencarian dalam ruang parameter yang dipilih. `StandardScaler` digunakan untuk mengubah fitur agar memiliki rata-rata nol dan varians satu. `SVC` (Support Vector Classifier) dari `sklearn.svm` adalah implementasi kelas untuk melakukan klasifikasi menggunakan metode SVM. Untuk evaluasi kinerja model, digunakan berbagai metrik seperti `accuracy_score`, `confusion_matrix`, `f1_score`, `recall_score`, dan `precision_score` dari `sklearn.metrics`. Terakhir, `matplotlib.pyplot` digunakan untuk membuat visualisasi seperti histogram, sementara `seaborn` digunakan untuk membuat heatmap dari confusion matrix untuk visualisasi yang lebih informatif.


```

1 | # Define features and target variable
2 | X = dataset.drop(['status'], axis=1)
3 | y = dataset['status']
4 |
5 | # Split data into train and test sets
6 | X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
    random_state=0)

```

Gambar 5.16 Pembagian data testing dan data training

Pada gambar 5.17 dataset dibagi menjadi dua bagian utama: fitur dan variabel target. Fitur-fitur dataset, yang merepresentasikan atribut-atribut dari setiap sampel data, disimpan dalam variabel X, sedangkan variabel target, yang berisi nilai yang ingin diprediksi oleh model, disimpan dalam variabel y. Selanjutnya, digunakan fungsi `train_test_split()` dari modul `sklearn.model_selection` untuk membagi dataset menjadi dua subset: data pelatihan dan data pengujian. Data pelatihan akan digunakan untuk melatih model, sedangkan data pengujian akan digunakan untuk menguji kinerja model yang telah dilatih. Proses pembagian data dilakukan dengan menentukan syntax `test_size=0.2`, yang menandakan bahwa 20% dari dataset akan dialokasikan untuk data pengujian.

Data yang telah dibagi kemudian akan diklasifikasikan menggunakan SVM dan akan dibuat sebuah model klasifikasi, berikut meruakan potongan program yang digunakan untuk melakukan training model.

```

1 | # Standardize features
2 | scaler = StandardScaler()
3 | X_train = scaler.fit_transform(X_train)
4 | X_test = scaler.transform(X_test)
5 |
6 | # Create SVM model
7 | svm_model = SVC()
8 |
9 | # Define hyperparameters
10| param_grid = {
11|     'C': [100],
12|     'kernel': ['rbf'],
13|     'gamma': [0.6],
14| }

```

Gambar 5.17 Program training Model

Dalam implementasi klasifikasi SVM pada program pelatihan model pada Gambar 5.18 hal yang pertama dilakukan adalah melakukan scaler menggunakan standard scaler dengan tujuan memiliki nilai skala yang sragam untuk meningkatkan kinerja algoritma SVM. Setelah normalisasi, dilakukan pembuatan model klasifikasi SVM menggunakan objek SVC (*Support Vector Classifier*) yang akan mempelajari pola dalam data pelatihan. Selanjutnya ditentukanlah

hyperparameter dari model svm, seperti 'c' (*regularization parameter*), 'kernel' (jenis kernel), dan 'gamma' (koefisien kernel). Dengan menggunakan hyperparameter yang telah ditentukan, dieksplorasi kombinasi hyperparameter yang menghasilkan model dengan kinerja optimal.

5.5 Implementasi Pengujian Hardware

Implementasi pengujian meliputi pengujian model svm terhadap 3 kelas roasting kopi. Pengujian dilakukan dengan menggunakan gas yang dihasilkan dari proses roasting kopi yang menghasilkan aroma gas kopi ketika light, medium dan dark. Alat e-nose yang telah dibuat diletakkan di sisi mesin roasting kopi, untuk cara mendeteksi aroma dari proses roasting kopi dipasang selang anti panas yang masuk pada corong mesin kopi yang membuang gas udara roasting kopi, hasil dari udara gas kopi kemudian disedot oleh vacuum pump yang ada pada e-nose, kemudian diteruskan pada chamber yang terletak pada e-nose untuk dilakukan prediksi hasil roasting kopi.


Gas yang dibaca oleh sensor akan di transfer menuju miniPC untuk ditampilkan hasilnya pada dashboard yang telah dibuat. Dan akan juga ditampilkan hasil klasifikasinya pada web dashboard yaitu light, medium, dan dark.

BAB VI

HASIL DAN PEMBAHASAN

6.1 Hasil Pembacaan Data

Nilai respon sensor terhadap aroma roasting kopi dipengaruhi oleh intensitas komponen aroma, selektivitas, sensitivitas, dan kestabilan sensor. Selain itu parameter suhu dan kelembapan pada *chamber* juga mempengaruhi respon sensor. Parameter intensitas aroma ditentukan oleh sampel aroma gas dari 3 kelas hasil roasting kopi.



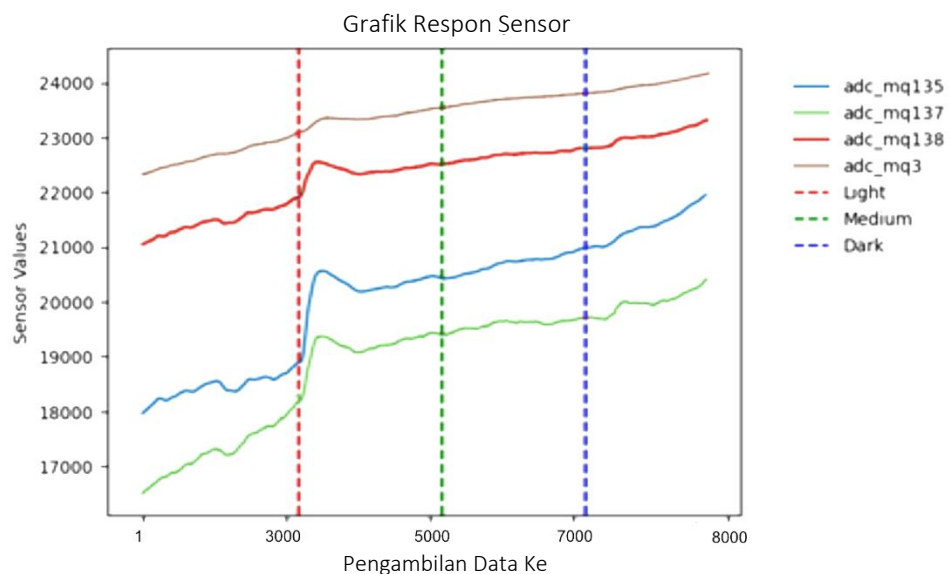
Gambar 6.1 Respon sensor terhadap pembacaan aroma Light, Medium, dan Dark

Gambar 6.1 memperlihatkan grafik dari hasil pembacaan sensor MQ135, MQ136, MQ137, MQ138, MQ2, MQ3, TGS822, dan TGS2620 terhadap aroma roasting kopi. Pada grafik terlihat sensor MQ2 memiliki pembacaan yang jauh berbeda dibanding dengan sensor lainnya, MQ2 membaca respon aroma gas dimulai dari value 8000, sedangkan sensor lainnya memiliki pembacaan awal yang dimulai 16000 hingga 22000. Pada hasil pembacaan ketika light MQ2 memiliki lonjakan pada pembacaan yang lumayan tinggi dibanding dengan sensor lainnya, setelah memasuki fase light respon sensor MQ2 terhadap aroma gas memasuki medium terus menurun hingga memasuki fase dark sama seperti sensor TGS2620 dan TGS822. Pada sensor MQ135 dan MQ136 hampir memiliki respon pembacaan yang sama terhadap aroma roasting kopi ketika ada di fase light, medium dan dark, ketika fase light memiliki lonjakan terhadap respon sensor, dan respon sensor terus

memiliki kenaikan secara perlahan sampai memasuki fase akhir yaitu dark. Kemudian pada sensor MQ138 memiliki karakter respon sensor yang hampir sama seperti MQ135 dan MQ136, tetapi untuk sensor MQ138 memulai respon terhadap pembacaannya di angka 21000 dibanding dengan sensor MQ135 dan MQ136 yang dimulai dari 18000. Pada sensor MQ3 memiliki respon sensor dan memiliki pembacaan yang dimulai dari value yang lebih tinggi dibanding dengan sensor lainnya, yaitu dimulai pada value 22000, untuk karakteristik respon sensor hampir mirip dengan sensor MQ135 dan MQ136 yaitu pada light terdapat lonjakan yang lumayan tinggi dan akan terus naik value nya sampai fase dark berakhir.

6.2 Hasil ciri pada setiap Kelas

Ciri pada setiap kelas dihasilkan dari selektivitas sensor yang merepresentasikan setiap kelasnya. Pada tahap ini dipilih sensor MQ135, MQ137, MQ138 dan MQ3 untuk dijadikan fitur pada tahap kasifikasinya.



Gambar 6.2 Visualisasi Ciri setiap kelasnya

Pada gambar 6.2 diperlihatkan hasil fitur yang digunakan yaitu sensor MQ135, MQ137, MQ138, dan MQ3 untuk klasifikasi di setiap kelasnya. Setiap kelas memiliki bentuk grafik yang berbeda, dan memiliki value yang berbeda. Pada kelas light memiliki bentuk grafik pada setiap sensornya yaitu memiliki lonjakan dibanding kelas medium, dan dark. Untuk kelas medium memiliki bentuk grafik yang value sensornya terus naik. Sedangkan untuk kelas dark memiliki bentuk

grafik yang valuenya terus naik dan memiliki lonjakan di akhirnya, sampai terjadi penurunan yang signifikan itu adalah grafik ketika hasil roasting kopi dikeluarkan dari mesin roasting kopi. Pada ciri setiap sensor gas yang pilih memiliki bentuk grafik yang hampir sama, tetapi yang membedakan di setiap sensornya adalah value atau respon sensornya.

6.3 Hasil Tahapan Klasifikasi

Data yang diperoleh dari hasil selektivitas sensor, dipersiapkan untuk dianalisis dengan SVM menggunakan perangkat lunak google colab, data yang digunakan untuk analisis dengan SVM merupakan data hasil ciri dari selektivitas sensor dengan jumlah total data 18000 data dengan 4 jenis sampel, sehingga terdapat 4500 data setiap sampel.

6.4 Hasil Pengujian Klasifikasi

Pada tahap penelitian ini, peneliti mengamati kinerja pada model SVM yang telah dibuat, dengan variasi nilai C dan gamma dengan jenis kernel RBF. Hasil pengujian menggunakan metode SVM untuk aroma gas roasting kopi light, medium dan dark menghasilkan nilai akurasi dan presisi yang digunakan untuk melihat performa model yang telah dibuat.

Tabel 6.1 Hasil Pelatihan Model C 10 dengan Gamma Variatif

C	Gamma	Akurasi(%)	Presisi(%)	Recall(%)	Specificity (%)
10	0.1	91	91	91	91
10	0.4	96	97	96	97
10	0.8	98	98	98	92

Tabel 6.2 Hasil Pengujian Model C 10 dengan Gamma Variatif

C	Gamma	Akurasi(%)	Presisi(%)	Recall(%)	Specificity (%)
10	0.1	90	90	91	91
10	0.4	98	98	98	98
10	0.8	96	96	96	92

Berdasarkan tabel 6.1 dan tabel 6.2 diatas menunjukkan hasil percobaan dengan nilai C yaitu 10 dan variasi nilai gamma 0.1, 0.4. dan 0.8. Dengan variasi C 10 dan gamma 0.1, kinerja model selama pelatihan dan pengujian menunjukkan

nilai akurasi, presisi, recall, dan spesitifitas sebesar 91% saat proses pelatihan dan 91% saat proses pengujian. Dengan variasi C 10 dan gamma 0.4, kinerja model menunjukkan akurasi 96%, presisi 97%, recall 96%, dan spesitifitas 97% saat proses pelatihan dan 98% saat proses pengujian. Dan untuk variasi C 10 dan gamma 0.8 menghasilkan akurasi dan presisi saat proses pelatihan sebesar 98% sedangkan ketika proses pengujian sebesar 98%. Berdasarkan ketiga percobaan di atas performa akurasi dan presisi memiliki nilai yang sama pada setiap variasinya. Pada proses pelatihan dapat dilihat bahwa semakin tinggi nilai gamma performa model yang dibuat semakin baik.

Berdasarkan perubahan nilai gamma dan C pada proses pelatihan di atas, semakin besar nilai C maka semakin baik juga kinerja yang dihasilkan, dan semakin besar nilai gamma maka semakin baik juga kinerja yang dihasilkan. Namun, performa di beberapa pengujian menunjukkan sebaliknya. Artinya semakin tinggi nilai gamma dan C yang ditentukan saat membuat model, semakin buruk kinerja model tersebut. Variabel C dan gamma merupakan parameter penting dari algoritma *support vector machine* (SVM) yang digunakan untuk menentukan bentuk model hyperplane yang digunakan untuk memisahkan kelas dalam suatu data tertentu.

Variabel C adalah parameter yang mengontrol trade-off antara memaksimalkan margin (jarak antara hyperplane dan titik terdekat dari kedua kelas) dan jumlah kesalahan klasifikasi dalam data pelatihan. Semakin besar nilai C, kemungkinan besar model SVM akan menangani data pelatihan akan semakin baik, namun hal ini juga dapat menyebabkan overfitting (model akan menyesuaikan data pelatihan secara berlebihan dan (tidak akan menggeneralisasi data dengan baik). Sebaliknya, semakin kecil nilai C, semakin besar toleransi terhadap kesalahan pada data pelatihan, dan semakin besar kemungkinan membuat model yang dapat digeneralisasikan dengan baik pada data yang belum pernah dilihat sebelumnya.

Gamma adalah parameter yang mengontrol bentuk fungsi kernel SVM. Gamma menentukan seberapa cepat nilai kernel menurun seiring bertambahnya jarak antara dua titik. Semakin kecil nilai gamma, semakin lambat penurunan nilai

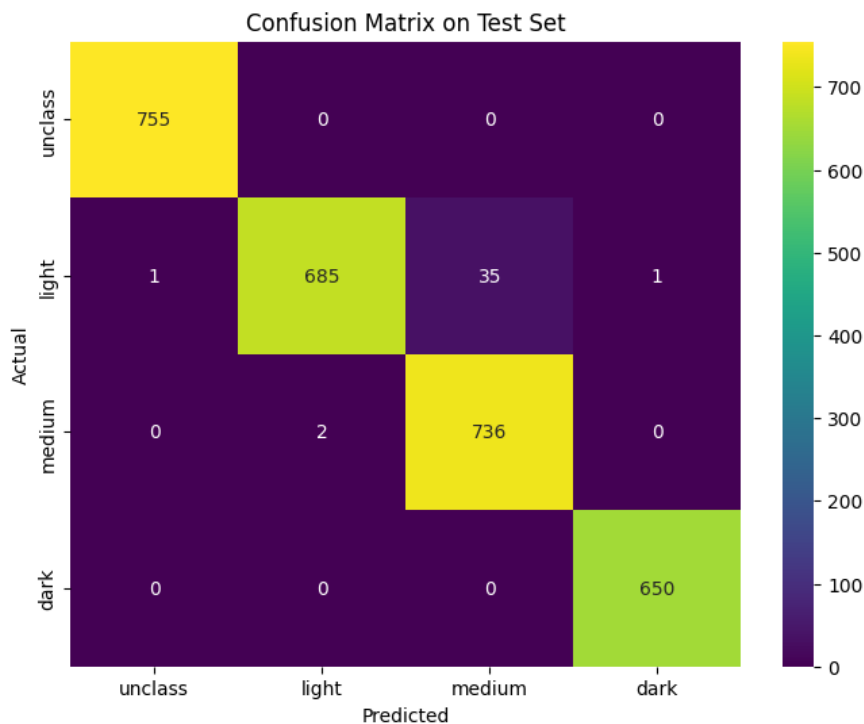
kernel seiring bertambahnya jarak antara dua titik, sehingga model SVM lebih cenderung mempertahankan pola global data. Sebaliknya, semakin besar nilai gamma, semakin cepat nilai kernel menurun seiring dengan bertambahnya jarak antara dua titik, dan semakin besar kemungkinan model SVM mendeteksi detail dan pola lokal dalam data. Pemilihan nilai yang sesuai untuk variabel C dan gamma bergantung pada data yang digunakan dan tugas yang dilakukan.

6.5 Pengujian Model

Pengujian model dilakukan terhadap data aroma gas pada mesin roasting kopi yang dilakukan secara realtime menggunakan metode SVM dengan nilai C 100 dan gamma 0.8 hal ini dikarenakan performa model stabil antara pelatihan dan pengujian.

Pengujian model dilakukan menggunakan e-nose dengan sensor gas larik yang akan mendeteksi gas hasil aroma gas kopi pada saat roasting kopi, Pada mesin roasting kopi terdapat corong atau saluran untuk membuang aroma kopi keluar, aroma kopi yang keluar akan di hisap oleh e-nose yang memiliki vacuum pump dan akan diteruskan ke dalam *chamber*, Kemudian sensor gas akan mendapatkan hasil pembacaan berupa sinyal tegangan. Sinyal tegangan dari beberapa sensor gas akan diklasifikasikan menggunakan model yang telah dibuat. Kemudian akan diberikan output kelas berdasarkan Tingkat kematangan kopi yang sesuai dengan dataset.

Confusion matrix adalah metode yang digunakan untuk mengevaluasi kinerja model atau algoritma klasifikasi. Label yang ditunjukkan pada *confusion matrix* menunjukkan hubungan data satu dengan data yang lainnya dalam proses klasifikasi. *Confusion matrix* dapat memberikan seberapa baik model dapat melakukan klasifikasi dengan data yang diinputkan, dengan membandingkan hasil prediksi model dengan nilai yang sebenarnya dari data tersebut. Pada penelitian ini didapatkan hasil *confusion matrix* pada gambar 6.3



Gambar 6.3 Confusion matrix pengujian secara realtime

Pada gambar 6.3 diperlihatkan hubungan antar kelas pada klasifikasi hasil roasting kopi secara realtime menggunakan model SVM yang telah dibuat. Confusion matrix digunakan untuk mendapatkan nilai TP, FP, TN, dan FN. Pada gambar diatas dapat dilihat bahwa nilai true positive untuk kelas unclass sebesar 755, kelas light sebesar 685, kelas medium sebesar 736, dan kelas dark sebesar 650. Nilai horizontal dari masing-masing kelas pada matrix menunjukkan nilai *False Negative*, sedangkan nilai vertikal dari masing-masing kelas pada matrix menunjukkan nilai *False Positive*. Nilai FP, TP, FN, dan TN pada *confusion matrix* dapat digunakan untuk mencari nilai akurasi, presisi, recall, dan spesifitas.

Tabel 6.3 Hasil Pengujian Model secara realtime

	TP	FP	FN	TN	Akurasi (%)	Recall (%)	Specifiticy (%)	Presisi (%)
unclass	755	1	0	2109	99	100	99	99
light	685	2	37	2141	98	94	99	99
medium	736	35	2	2092	98	99	98	95
dark	650	1	0	2214	99	100	99	99

Hasil evaluasi klasifikasi yang ditunjukkan oleh Tabel 6.3 yang dilakukan menggambarkan kinerja model terhadap masing-masing kelas, dengan memperhatikan konsep True Positive (TP), False Positive (FP), False Negative (FN), dan True Negative (TN). TP mengacu pada jumlah sampel positif yang berhasil diklasifikasikan dengan benar oleh model, sementara FP menunjukkan jumlah sampel negatif yang salah diklasifikasikan sebagai positif. FN menggambarkan jumlah sampel positif yang seharusnya diklasifikasikan sebagai positif, namun salah diklasifikasikan sebagai negatif oleh model. Sedangkan TN mencerminkan jumlah sampel negatif yang berhasil diklasifikasikan dengan benar oleh model. Dengan demikian, untuk kelas "unclass", terdapat 755 TP, 1 FP, tidak ada FN, dan 2109 TN. Begitu pula untuk kelas "dark", dengan 650 TP, 1 FP, tidak ada FN, dan 2214 TN. Namun, untuk kelas "light" dan "medium", terdapat beberapa kasus di mana model mengalami kesalahan dalam klasifikasi, seperti 37 FN untuk kelas "light" dan 35 FP untuk kelas "medium".

Berdasarkan tabel 6.3 pengujian real-time menggunakan model SVM menunjukkan akurasi yang relative bagus. Pada kelas unclass menunjukkan akurasi 99%, recall 100%, Specifiticy 99% dan presisi 99%. Dalam hal ini menunjukkan bahwa model SVM yang dibuat dapat mengklasifikasikan dengan baik. Untuk kelas light hasil pembacaan dari aroma kopi ketika light menunjukkan nilai akurasi 98%, recall 94%, specifiticy 99% dan presisi 99%. Berdasarkan pengujian pada aroma ketika medium menunjukkan hasil akurasi 98%, recall 99%, specifiticy 98% dan presisi 95%. Dan kelas terakhir yaitu dark menunjukkan hasil akurasi 99%, recall 100%, specifiticy 99% dan presisi 99%.

Berdasarkan tabel 6.3 model SVM yang dibuat telah berhasil mengklasifikasikan kelas light, medium, dan dark dengan baik dengan menggunakan kernel RBF.

BAB VII

PENUTUP

7.1 Kesimpulan

Telah dilakukan penelitian identifikasi kematangan roasting kopi menggunakan metode Support Vector Machine menggunakan e-nose dapat yang dapat disimpulkan sebagai berikut:

1. Teknologi e-nose yang dikembangkan oleh peneliti telah menunjukkan keberhasilan dalam mengidentifikasi tingkat kematangan roasting kopi secara real-time dengan menggunakan 4 fitur dari sensor MQ135, MQ137, MQ138, dan MQ3.
2. Metode klasifikasi menggunakan SVM yang paling optimal dalam melakukan klasifikasi dengan menggunakan nilai cost 0.8 dan gamma sebesar 10.
3. Performa model saat pengujian secara realtime didapatkan rerata akurasi 98,5%, recall 98,2%, spesitifitas 98,7%, dan presisi 98%. Hasil pengujian yang dilakukan secara realtime menunjukkan bahwa model SVM mampu mengklasifikasikan aroma kematangan kopi dengan tingkat akurasi yang tinggi, menegaskan kemampuan teknologi e-nose dalam mendukung proses evaluasi kualitas kematangan kopi.

7.2 Saran

Saran yang diberikan untuk pengembangan penelitian selanjutnya sebagai berikut:

1. Data set perlu ditambah dengan menambah jenis sampel yaitu jenis kopi lainnya, dan variasi takaran agar lebih variatif lagi serta jumlah dataset untuk meningkatkan performa sistem untuk mengidentifikasi kematangan kopi pada berbagai jenis kopi.
2. Diperlukan untuk menambah metode klasifikasi yang lain untuk membandingkan dengan beberapa metode klasifikasi yang sudah digunakan.

DAFTAR PUSTAKA

- Abbas, F. N., Saadoon, I. M., Abdalrdha, Z. K., & Abud, E. N. (2020). Capable of gas sensor MQ-135 to monitor the air quality with Arduino Uno. *Int. J. Eng. Res. Technol*, 13(10), 2955-2959.
- Abdullah, S. S., Yusup, S., Ahmad, M. M., Ramli, A., & Ismail, L. (2010). Thermogravimetry study on pyrolysis of various lignocellulosic biomass for potential hydrogen production. *International Journal of Chemical and Molecular Engineering*, 4(12), 750-754.
- Al Farobi, O., 2021, Implementasi Metode Support Vector Machine (SVM) untuk mengetahui respon Masyarakat Indonesia terhadap pemberian vaksin sinovac (Bachelor's thesis, Fakultas Sains dan Teknologi Universitas Islam Negeri
- Agustina, R., Nurba, D., Antono, W., & Septiana, R. (2019, June). Pengaruh suhu dan lama penyangraian terhadap sifat fisik-kimia kopi arabika dan kopi robusta. In *Prosiding Seminar Nasional Inovasi Teknologi Untuk Masyarakat* (Vol. 53, No. 9, pp. 285-299).
- Bahrumi, P., Ratna, R., & Fadhil, R. (2022). Levelisasi Penyangraian Kopi: Suatu Kajian. *Jurnal Ilmiah Mahasiswa Pertanian*, 7(1).
- Baskara, S., Lelono, D., & Widodo, T. W. (2016). Pengembangan Hidung Elektronik untuk Klasifikasi Mutu Minyak Goreng dengan Metode Principal Component Analysis. *IJEIS (Indonesian J. Electron. Instrum. Syst*, 6(2), 221.
- Bi, Q., Goodman, K. E., Kaminsky, J., & Lessler, J. (2019). What is machine learning? A primer for the epidemiologist. *American journal of epidemiology*, 188(12), 2222-2239.
- Binson, V. A., George, M. M., Sibichan, M. A., Raj, M., & Prasad, K. (2023, January). Freshness Evaluation of Beef using MOS Based E-Nose. In *2023 International Conference on Intelligent Data Communication Technologies and Internet of Things (IDCIoT)* (pp. 792-797). IEEE.
- Delmo, J. A. B., Villarica, M. V., & Vinluan, A. A. (2022, May). Classification of Coffee Variety using Electronic Nose. In *2022 IEEE 18th International Colloquium on Signal Processing & Applications (CSPA)* (pp. 248-253). IEEE.
- Hernández, J. A., Heyd, B., & Trystram, G. (2008). Prediction of brightness and surface area kinetics during coffee roasting. *Journal of Food Engineering*, 89(2), 156-163.
- Karimi, Z., 2021. Confusion Matrix. *Encycl. Mach. Learn. Data Min.*, no. October, pp.260-260.
- Kusumadewi, S. (2004). Membangun Jaringan Syaraf Tiruan Menggunakan MATLAB & EXCEL LINK. *Yogyakarta: Graha Ilmu*.
- Lelono, D., & Prastya, K. (2013). Karakterisasi Pola dan Konsentrasi Gas Polutan Berbasis E-Nose. *IJEIS (Indonesian Journal of Electronics and Instrumentation Systems)*, 3(1), 83-94.

- Magfira, D. B., & Sarno, R. (2018, March). Classification of Arabica and Robusta coffee using electronic nose. In *2018 International Conference on Information and Communications Technology (ICOIACT)* (pp. 645-650). IEEE.
- Mukhopadhyay, Sayan, 2022. *Advanced Data Analytics Using Python: With Machine Learning, Deep Learning, and NLP Examples* (pp. 49-75). Berkeley, CA: Apress.
- Putra, M. L. R., Rivai, M., & Irfansyah, A. N. (2019, May). Unmanned surface vehicle navigation based on gas sensors and fuzzy logic control to localize gas source. In *Journal of Physics: Conference Series* (Vol. 1201, No. 1, p. 012001). IOP Publishing.
- Rao, S., (2014), *The Coffee Roaster's Companion*, Scott Rao, New York.
- Sitohang, M. E. (2012). Analisis Sinyal Electronic Nose Berbasis Wavelet Menggunakan Support Vector Machine untuk Identifikasi Jenis Teh Hitam. *Jurnal Sistem Komputer*, 2(2), 47-53.
- Sumanto, B., Java, D. R., Wijaya, W., & Hendry, J. (2022). Seleksi Fitur Terhadap Performa Kinerja Sistem E-Nose untuk Klasifikasi Aroma Kopi Gayo. *MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer*, 21(2), 429-438.
- Telaumbanua, M., Novita, D. D., Triyono, S., & Saragih, C. (2021). Tipe chamber dan posisi sensor e-nose untuk mendeteksi aroma biji kopi robusta menggunakan mikrokontroler. *Jurnal Ilmiah Rekayasa Pertanian dan Biosistem*, 9(1), 84-95.
- Xu, Y., Shaull, J., Bavar, T., & Tan, L. (2018, January). Smart coffee roaster design with connected devices. In *2018 IEEE International Conference on Consumer Electronics (ICCE)* (pp. 1-5). IEEE.
- Yashin, Alexander, et al. "Chromatographic methods for coffee analysis: a review." *Journal of Food Research* 6.4 (2017): 60-82.